BỘ CÔNG THƯƠNG
TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



LƯƠNG CÔNG PHÚ BOY - 22002515

TRẦN ANH KHOA - 22000915

PHÂN LOẠI ÂM THANH ĐÔ THỊ SỬ DỤNG DEEP LEARNING

Ngành: Khoa học dữ liệu

Giảng viên hướng dẫn: TS. Huỳnh Công Bằng
TS. Nguyễn Minh Hạnh

THÀNH PHỐ HỒ CHÍ MINH, THÁNG 10 NĂM 2026

BỘ CÔNG THƯƠNG
TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



LƯƠNG CÔNG PHÚ BOY - 22002515

TRẦN ANH KHOA - 22000915

PHÂN LOẠI ÂM THANH ĐÔ THỊ SỬ DỤNG DEEP LEARNING

Ngành: Khoa học dữ liệu

Giảng viên hướng dẫn: TS. Huỳnh Công Bằng
TS. Nguyễn Minh Hạnh

THÀNH PHỐ HỒ CHÍ MINH, THÁNG 10 NĂM 2026

INDUSTRIAL UNIVERSITY OF HO CHI MINH CITY
FACULTY OF INFORMATION TECHNOLOGY



LUONG CONG PHU BOY - 22002515

TRAN ANH KHOA - 22000915

URBAN SOUND CLASSIFICATION USING DEEP LEARNING

Major: Data Science

Supervisors: Dr. Huynh Cong Bang

Dr. Nguyen Minh Hanh

HO CHI MINH CITY – OCTOBER 2026

URBAN SOUND CLASSIFICATION USING DEEP LEARNING

ABSTRACT

This thesis investigates deep learning methods for classifying seven urban sound categories selected from UrbanSound8K: car horn, children playing, dog bark, engine idling, gunshot, siren and drilling. The study compares a four-block convolutional network, a residual CNN with channel attention, and an Audio Spectrogram Transformer initialized from an AudioSet-pretrained checkpoint. A weighted probability ensemble is also evaluated.

The experimental pipeline checks audio validity and duplicate recordings, converts signals to mono at 16 kHz, and separates training, validation and test data by the predefined folds. After removing six training excerpts sharing recording sources with higher-priority partitions, the sets contain 4,632, 553 and 541 excerpts, respectively. CNN features are normalized using training-only statistics for each Mel band. Checkpoints and ensemble weights are selected on validation macro-F1.

On test fold 10, AST achieves 92.05% accuracy and 91.88% macro-F1. CNN4 reaches 85.58% accuracy and 87.23% macro-F1, while ResCNN reaches 83.73% and 86.11%. The ensemble matches AST accuracy but does not improve test macro-F1. Error analysis identifies siren-to-dog-bark and drilling-to-car-horn confusions as the dominant error groups. A local application provides audio upload, recording and probability visualization.

These findings are limited to a seven-class, single-fold experiment. They are not ten-fold UrbanSound8K benchmark results. Broader evaluation requires multiple folds and seeds, an independent out-of-class dataset, and a version-locked deployment package.

Keywords: urban sound classification, deep learning, Log-Mel spectrogram, convolutional neural network, Audio Spectrogram Transformer.

TÓM TẮT

Khóa luận nghiên cứu bài toán phân loại bảy nhóm âm thanh đô thị được chọn từ UrbanSound8K, gồm còi xe, trẻ em vui chơi, chó sủa, động cơ chạy không tải, tiếng súng, còi báo động và tiếng khoan. Nhóm so sánh CNN4, ResCNN có chú ý kênh và Audio Spectrogram Transformer được khởi tạo từ checkpoint pretrained trên AudioSet. Phương án ensemble xác suất có trọng số được đánh giá như một cách kết hợp các mô hình.

Quy trình thực nghiệm kiểm tra tệp âm thanh, mã băm và nguồn ghi âm trước khi tạo đặc trưng. Tín hiệu được đưa về mono 16 kHz với cửa sổ 4 giây. Sau khi loại sáu mẫu train giao nguồn với tập ưu tiên cao hơn, train có 4.632 mẫu, validation 553 mẫu và test 541 mẫu. Thống kê chuẩn hóa CNN được tính riêng theo dải Mel trên train. Checkpoint và trọng số kết hợp được chọn bằng validation macro-F1.

Trên test fold 10, AST đạt accuracy 92,05% và macro-F1 91,88%. CNN4 đạt 85,58% và 87,23%; ResCNN đạt 83,73% và 86,11%. Ensemble có accuracy bằng AST nhưng chưa cải thiện macro-F1 trên test. Phân tích lỗi cho thấy hai nhóm nhầm lẫn đáng chú ý là còi báo động thành chó sủa và tiếng khoan thành còi xe. Ứng dụng cục bộ hỗ trợ tải tệp, ghi âm và xem xác suất theo lớp.

Kết quả phản ánh một phép chia bảy lớp, chưa phải đánh giá chéo mười fold của benchmark gốc. Hướng phát triển tập trung vào đánh giá nhiều fold, nhiều seed, dữ liệu ngoài lớp và thống nhất gói triển khai với phiên bản đã huấn luyện.

Từ khóa: phân loại âm thanh đô thị, học sâu, phổ Log-Mel, mạng tích chập, Audio Spectrogram Transformer.

LỜI CẢM ƠN

Nhóm chúng em xin gửi lời cảm ơn đến TS. Huỳnh Công Bằng và TS. Nguyễn Minh Hạnh đã hướng dẫn đề tài khóa luận tốt nghiệp “Phân loại âm thanh đô thị sử dụng Deep Learning”. Sự hướng dẫn của thầy, cô là cơ sở để nhóm định hướng nội dung nghiên cứu và hoàn thiện báo cáo.

Chúng em cảm ơn các thầy, cô Khoa Công nghệ Thông tin, Trường Đại học Công nghiệp Thành phố Hồ Chí Minh đã giảng dạy những kiến thức nền tảng về lập trình, xử lý dữ liệu và học máy. Những kiến thức này giúp nhóm tiếp cận tài liệu chuyên ngành, tổ chức thực nghiệm và phân tích kết quả của đề tài.

Nhóm cũng trân trọng công sức của các tác giả UrbanSound8K và những công trình, thư viện nguồn mở được sử dụng. Việc công bố dữ liệu, mã nguồn và mô hình đã tạo điều kiện để sinh viên có thể tìm hiểu và kiểm tra các phương pháp học sâu trên bài toán âm thanh.

Trong phạm vi thời gian và kinh nghiệm còn hạn chế, báo cáo khó tránh khỏi thiếu sót. Nhóm mong nhận được ý kiến của thầy, cô để tiếp tục hoàn thiện phương pháp và cách trình bày kết quả.

Nhóm sinh viên thực hiện

Lương Công Phú Boy

Trần Anh Khoa

NHẬN XÉT CỦA GIÁO VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

TP. Hồ Chí Minh, ngày…. Tháng …. năm…….

CHỮ KÝ CỦA GIẢNG VIÊN

NHẬN XÉT CỦA GIÁO VIÊN PHẢN BIỆN 1

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

TP. Hồ Chí Minh, ngày…. Tháng …. năm…….

CHỮ KÝ CỦA GIẢNG VIÊN

NHẬN XÉT CỦA GIÁO VIÊN PHẢN BIỆN 2

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

TP. Hồ Chí Minh, ngày…. Tháng …. năm…….

CHỮ KÝ CỦA GIẢNG VIÊN

MỤC LỤC

CHƯƠNG 1 GIỚI THIỆU VỀ BÀI TOÁN..... 1
1.1 Bối cảnh và lý do chọn đề tài..... 1
1.2 Phát biểu bài toán..... 1
1.3 Mục tiêu và câu hỏi nghiên cứu..... 2
1.4 Phạm vi và phương pháp thực hiện..... 3
1.5 Kết quả chính..... 3
CHƯƠNG 2 CƠ SỞ LÝ THUYẾT VÀ NGHIÊN CỨU LIÊN QUAN..... 4
2.1 Tín hiệu âm thanh số..... 4
2.2 Biến đổi Fourier ngắn hạn và biểu diễn Mel..... 4
2.3 Mạng nơ-ron tích chập..... 5
2.4 Kết nối phần dư và chú ý kênh..... 6
2.5 Audio Spectrogram Transformer và học chuyển giao..... 6
2.6 Tăng cường dữ liệu và hàm mất mát..... 7
2.7 Các nghiên cứu liên quan và hướng tiếp cận của nhóm..... 8
CHƯƠNG 3 DỮ LIỆU VÀ THIẾT KẾ THỰC NGHIỆM..... 9
3.1 Nguồn gốc và cấu trúc dữ liệu..... 9
3.2 Lựa chọn bảy lớp và khảo sát ban đầu..... 9
3.3 Kiểm tra chất lượng và kiểm soát rò rỉ..... 12
3.4 Chia tập huấn luyện và đánh giá..... 12
3.5 Tiền xử lý cho CNN..... 14
3.6 Tiền xử lý và tăng cường dữ liệu cho AST..... 15
3.7 Chỉ số và nguyên tắc đánh giá..... 15
CHƯƠNG 4 PHƯƠNG PHÁP VÀ HIỆN THỰC HỆ THỐNG..... 17
4.1 Kiến trúc tổng thể..... 17
4.2 Mô hình CNN4..... 17
4.3 Mô hình ResCNN có chú ý kênh..... 18
4.4 Tinh chỉnh AST..... 19
4.5 Huấn luyện và lựa chọn checkpoint..... 20
4.6 Ensemble xác suất..... 22
4.7 Hiện thực ứng dụng minh họa..... 22
4.8 Khả năng tái lập và quản lý kết quả..... 23

CHƯƠNG 5 THỰC NGHIỆM VÀ ĐÁNH GIÁ..... 24
5.1 Môi trường và căn cứ số liệu..... 24
5.2 Quá trình học của các mô hình.....25
5.3 Kết quả tổng thể trên tập kiểm tra.....27
5.4 Phân tích theo từng lớp..... 28
5.5 Ma trận nhầm lẫn và các lỗi nổi bật.....30
5.6 ROC và biểu diễn đặc trưng.....32
5.7 Chi phí tính toán và lựa chọn triển khai.....33
5.8 Minh họa suy luận và kiểm tra ứng dụng..... 35
5.9 Giới hạn và nguy cơ sai lệch.....35
CHƯƠNG 6 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN..... 37
6.1 Những nội dung đã thực hiện.....37
6.2 Hướng phát triển.....37
TÀI LIỆU THAM KHẢO.....a
PHỤ LỤC.....
NHẬT KÝ LÀM VIỆC.....

DANH MỤC HÌNH ẢNH

Hình 3.1 Phân bố dữ liệu của bảy lớp trước khi chia tập..... 10
Hình 3.2 Dạng sóng và phổ Log-Mel của các mẫu âm thanh..... 11
Hình 3.3 Phân bố lớp trên train validation và test..... 13
Hình 3.4 Phân bố đặc trưng trước và sau chuẩn hóa theo dải Mel.....14
Hình 4.1 Luồng xử lý dữ liệu huấn luyện và suy luận..... 17
Hình 4.2 Kiến trúc CNN4 dùng trong notebook thực nghiệm..... 18
Hình 4.3 Khối phần dư với chú ý kênh và tầng phân loại ResCNN..... 19
Hình 4.4 Quy trình đưa phổ vào AST và tinh chỉnh cho bảy lớp.....20
Hình 5.1 So sánh diễn biến huấn luyện của CNN4 ResCNN và AST.....25
Hình 5.2 Đường cong học của CNN4.....25
Hình 5.3 Đường cong học của ResCNN.....26
Hình 5.4 Đường cong học của AST pretrained..... 26
Hình 5.5 Accuracy và macro-F1 trên tập kiểm tra..... 27
Hình 5.6 So sánh F1 của bốn phương án theo lớp.....29
Hình 5.7 Ma trận nhầm lẫn của AST..... 30
Hình 5.8 Các cặp nhãn nhầm lẫn xuất hiện nhiều nhất..... 30
Hình 5.9 Ma trận nhầm lẫn của CNN4..... 31
Hình 5.10 Ma trận nhầm lẫn của ResCNN..... 31
Hình 5.11 Đường ROC theo cách one-vs-rest của các mô hình..... 32
Hình 5.12 Chiếu PCA hai chiều của đặc trưng các mô hình.....33
Hình 5.13 Tổng hợp quy mô tốc độ và chất lượng của các mô hình..... 34
Hình 5.14 So sánh dự đoán trên mẫu âm thanh minh họa của notebook.....35

DANH MỤC BẢNG BIỂU

Bảng 3.1 Tập nhãn được sử dụng trong đề tài..... 10
Bảng 3.2 Phân bố số mẫu theo lớp sau khi chia tập và loại nguồn trùng.... 13
Bảng 4.1 Cấu hình huấn luyện trong notebook đã chạy..... 21
Bảng 5.1 So sánh các mô hình trên test fold 10 với 541 mẫu..... 27
Bảng 5.2 Precision recall và F1 của AST theo lớp trên test fold 10..... 28
Bảng 5.3 Quy mô mô hình và thời gian huấn luyện đã ghi nhận..... 33
Bảng A.1 Các tệp dùng để kiểm tra số liệu.....
Bảng B.1 Nhật ký công việc theo tuần.....

DANH MỤC CÁC THUẬT NGỮ VIẾT TẮT

Viết tắt	Thuật ngữ	Nghĩa
AMP	Automatic Mixed Precision	Độ chính xác hỗn hợp tự động
AST	Audio Spectrogram Transformer	Transformer trên phổ âm thanh
AUC	Area Under the Curve	Diện tích dưới đường cong
BN	Batch Normalization	Chuẩn hóa theo batch
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
CPU	Central Processing Unit	Bộ xử lý trung tâm
CSV	Comma-Separated Values	Dữ liệu phân tách bằng dấu phẩy
GPU	Graphics Processing Unit	Bộ xử lý đồ họa
PCA	Principal Component Analysis	Phân tích thành phần chính
ReLU	Rectified Linear Unit	Hàm kích hoạt tuyến tính chỉnh lưu
ROC	Receiver Operating Characteristic	Đường đặc trưng hoạt động
SE	Squeeze-and-Excitation	Cơ chế chú ý theo kênh
STFT	Short-Time Fourier Transform	Biến đổi Fourier ngắn hạn

CHƯƠNG 1
GIỚI THIỆU VỀ BÀI TOÁN

1.1 Bối cảnh và lý do chọn đề tài

Âm thanh là một nguồn thông tin quen thuộc trong sinh hoạt đô thị. Tiếng còi xe, tiếng động cơ, tiếng chó sủa hay tiếng khoan đều phản ánh một phần hoạt động đang diễn ra xung quanh người nghe. Trong nhiều trường hợp, âm thanh xuất hiện trước khi nguồn phát nằm trong tầm quan sát của camera. Khả năng nhận biết các tín hiệu này có thể hỗ trợ khảo sát môi trường âm thanh, tra cứu dữ liệu ghi âm và xây dựng những ứng dụng nhận biết sự kiện ở mức cơ bản.

Khác với lời nói được ghi trong điều kiện tương đối ổn định, âm thanh ngoài đường thường đi kèm nhiều nguồn nhiễu. Cùng một loại tiếng động có thể thay đổi theo khoảng cách, thiết bị thu, vật cản và bối cảnh. Một đoạn có tiếng trẻ em cũng có thể chứa tiếng xe; tiếng động cơ và tiếng khoan có những thành phần tần số chồng lấn. Vì vậy, chỉ dựa trên độ lớn hoặc một vài đặc trưng thủ công thường chưa đủ để phân biệt các lớp một cách ổn định.

Nhóm chọn đề tài “Phân loại âm thanh đô thị sử dụng Deep Learning” để tìm hiểu cách biểu diễn tín hiệu âm thanh và so sánh các mô hình học sâu trong cùng một quy trình thực nghiệm. Trọng tâm của khóa luận là mối liên hệ giữa dữ liệu, tiền xử lý, kiến trúc mô hình và cách đánh giá. Ứng dụng minh họa được xây dựng để người dùng có thể thử dự đoán trên tệp âm thanh, quan sát phân bố xác suất và xem biểu diễn tín hiệu.

1.2 Phát biểu bài toán

Đầu vào của hệ thống là một đoạn âm thanh số. Sau khi giải mã, hệ thống chuyển tín hiệu về một kênh, lấy mẫu ở 16 kHz và tạo cửa sổ dài 4 giây. Mô hình trả về một vector gồm bảy giá trị softmax ứng với bảy lớp mục tiêu. Nhãn dự đoán là lớp có giá trị lớn nhất. Đây là bài toán phân loại đơn nhãn ở cấp đoạn âm thanh, không

phải phát hiện đồng thời nhiều sự kiện hoặc xác định thời điểm bắt đầu và kết thúc của từng sự kiện.

Trong phạm vi thực nghiệm, bảy lớp được giữ lại từ UrbanSound8K gồm còi xe, trẻ em vui chơi, chó sủa, động cơ chạy không tải, tiếng súng, còi báo động và tiếng khoan. Ba lớp air_conditioner, jackhammer và street_music không được đưa vào huấn luyện. Tiếng búa phá đường không được gộp với tiếng khoan. Việc thu hẹp nhãn giúp tập trung vào một bài toán có thể triển khai và phân tích trong điều kiện tài nguyên của nhóm, nhưng cũng làm cho kết quả khác với benchmark mười lớp nguyên bản.

Với mẫu x và nhãn y thuộc tập bảy lớp, mô hình học một ánh xạ từ đặc trưng của x sang phân bố p(y|x). Nhãn được gán theo sự kiện đã có trong metadata. Khi đưa một tệp chứa nhiều nguồn âm vào ứng dụng, kết quả chỉ thể hiện lựa chọn của mô hình trong tập nhãn này; hệ thống chưa có cơ chế tách nguồn để xác định mọi âm thanh cùng xuất hiện.

1.3 Mục tiêu và câu hỏi nghiên cứu

Mục tiêu thứ nhất là xây dựng một luồng xử lý có thể theo dõi từ dữ liệu gốc đến kết quả cuối. Luồng này bao gồm kiểm tra tệp, khảo sát phân bố nhãn, chia tập theo fold và nguồn ghi âm, chuẩn hóa đặc trưng trên tập huấn luyện, lưu checkpoint và tổng hợp các chỉ số đánh giá. Mỗi bảng kết quả cần có tệp dữ liệu đi kèm để có thể kiểm tra lại.

Mục tiêu thứ hai là so sánh CNN4, ResCNN và AST trong cùng tập huấn luyện, validation và test. CNN4 đóng vai trò mô hình nền tương đối gọn; ResCNN khảo sát kết nối tắt và chú ý kênh; AST khai thác biểu diễn đã học từ dữ liệu lớn. Ensemble được bổ sung để xem việc kết hợp xác suất có cải thiện so với từng mô hình riêng lẻ hay không.

Từ các mục tiêu trên, nhóm đặt ra ba câu hỏi. Học chuyển giao với AST thay đổi macro-F1 và chi phí tính toán như thế nào so với CNN huấn luyện từ đầu? Các lớp

nào còn gây nhầm lẫn dù accuracy chung đã cao? Ensemble được chọn bằng validation có giữ được lợi ích trên test hay chỉ làm tăng độ phức tạp? Các câu hỏi được trả lời bằng số liệu của lần chạy đã lưu, thay vì suy luận chỉ từ độ sâu hoặc số tham số của mạng.

1.4 Phạm vi và phương pháp thực hiện

Nguồn dữ liệu chính là UrbanSound8K, một bộ dữ liệu âm thanh môi trường có nhãn được công bố phục vụ nghiên cứu. Bộ gốc gồm 8.732 đoạn thuộc mười lớp và được tổ chức sẵn thành mười fold [8]. Phần dữ liệu bảy lớp trong dự án có 5.732 đoạn hợp lệ trước khi loại các nguồn giao nhau giữa các tập. Nhóm sử dụng fold 10 làm test, fold 1 làm validation và các fold còn lại làm train.

Thực nghiệm hiện tại chỉ có một phép chia holdout. Do chưa chạy đủ mười lượt kiểm định chéo, kết quả không đại diện cho điểm benchmark UrbanSound8K và không được dùng để tuyên bố vượt các công trình dùng giao thức khác. Nhóm đồng thời kiểm tra fsID và ưu tiên giữ nguồn ở test, sau đó loại các mẫu cùng nguồn khỏi train khi cần. Quy tắc này làm thay đổi tập fold gốc và phải được xét khi diễn giải kết quả.

Phương pháp thực hiện gồm đọc tài liệu gốc, khảo sát dữ liệu, xây dựng mô hình, huấn luyện có giám sát và phân tích lỗi. Các chỉ số chính là accuracy, macro-precision, macro-recall và macro-F1. Ma trận nhầm lẫn và chỉ số theo lớp được dùng để giải thích kết quả. Thời gian xử lý và dung lượng checkpoint chỉ được so sánh trong điều kiện đo đã lưu, không được coi là cam kết tốc độ cho mọi thiết bị.

1.5 Kết quả chính

Trên 541 mẫu test của lần chạy hiện tại, AST đạt accuracy 92,05% và macro-F1 91,88%. CNN4 đạt lần lượt 85,58% và 87,23%; ResCNN đạt 83,73% và 86,11%. Ensemble có cùng accuracy với AST nhưng macro-F1 thấp hơn khoảng 0,02 điểm phần trăm. Kết quả cho thấy lợi ích của mô hình pretrained trong thiết lập này, đồng thời cho thấy việc kết hợp nhiều mạng chưa đương nhiên mang lại cải thiện.

CHƯƠNG 2
CƠ SỞ LÝ THUYẾT VÀ NGHIÊN CỨU LIÊN QUAN

2.1 Tín hiệu âm thanh số

Âm thanh được số hóa bằng cách lấy mẫu biên độ theo thời gian. Tần số lấy mẫu cho biết số mẫu trong một giây; với tín hiệu 16 kHz, mỗi giây có 16.000 giá trị. Theo quan hệ Nyquist, miền tần số biểu diễn được bị giới hạn dưới một nửa tần số lấy mẫu. Lựa chọn 16 kHz vì vậy phù hợp với pipeline hiện có nhưng cũng loại bỏ các thành phần tần số cao hơn 8 kHz của bản ghi gốc.

Một tệp có thể gồm một hoặc nhiều kênh. Khi chuyển stereo về mono bằng trung bình các kênh, hệ thống giảm sự khác nhau về hình dạng đầu vào và chi phí tính toán. Đổi lại, thông tin không gian giữa hai kênh không còn được giữ. Đề tài sử dụng nội dung phổ và biến đổi theo thời gian để phân loại, không nghiên cứu định vị hướng nguồn âm.

Dạng sóng biểu diễn biên độ theo thời gian, hữu ích khi phát hiện đoạn im lặng, đỉnh xung hoặc tín hiệu bị cắt ngọn. Tuy nhiên, hai âm thanh có cấu trúc phổ khác nhau vẫn có thể trông khá giống nhau trên waveform. Do đó, nhóm kết hợp quan sát waveform với phổ thời gian–tần số trước khi đưa dữ liệu vào mô hình.

2.2 Biến đổi Fourier ngắn hạn và biểu diễn Mel

Biến đổi Fourier ngắn hạn chia tín hiệu thành những cửa sổ ngắn rồi phân tích phổ của từng cửa sổ. Cách biểu diễn này dựa trên giả định tín hiệu gần ổn định trong một khoảng ngắn. Cửa sổ lớn cho khả năng phân biệt tần số tốt hơn nhưng làm giảm độ phân giải thời gian; cửa sổ nhỏ có tác dụng ngược lại. Việc chọn tham số vì thế gắn trực tiếp với những cấu trúc cần nhận diện trong âm thanh.

$$X(m,k) = \Sigma_n \, x[n]w[n - mH]\exp(-j2\pi kn/N) \qquad (2.1)$$

Trong công thức (2.1), x[n] là tín hiệu rời rạc, w là hàm cửa sổ, H là bước dịch và N là số điểm biến đổi. Mỗi cột của phổ tương ứng với một cửa sổ thời gian. Phổ công

suất được lấy từ bình phương độ lớn của X. Các bộ lọc Mel tiếp tục cộng có trọng số năng lượng ở những vùng tần số khác nhau.

Thang Mel bố trí độ phân giải dày hơn ở vùng tần số thấp và thưa hơn ở vùng cao. Sau bộ lọc, phép log nén dải động để những khác biệt về năng lượng không chi phối toàn bộ biểu diễn. Ảnh Log-Mel không phải ảnh chụp nguồn âm; hai trục của nó lần lượt mang ý nghĩa thời gian và tần số. Cách diễn giải này cần được giữ khi áp dụng các phép biến đổi hoặc cơ chế chú ý.

$$M(b,m) = \Sigma_k H_b(k)|X(m,k)|^2;\ \ L(b,m) = 10\log_{10}(\max(M(b,m), \varepsilon)) \qquad (2.2)$$

Nhánh CNN dùng 64 dải Mel, n_fft bằng 1.024 và hop_length bằng 256. Ở 16 kHz, khoảng dịch giữa hai khung là 16 ms. Nhánh AST dùng bộ trích xuất đi kèm checkpoint pretrained với 128 dải Mel và tối đa 1.024 khung. Hai nhánh không dùng chung toàn bộ tham số đặc trưng vì AST cần duy trì quy ước đầu vào của mô hình đã được huấn luyện trước.

2.3 Mạng nơ-ron tích chập

Mạng nơ-ron tích chập, hay Convolutional Neural Network (CNN), sử dụng các bộ lọc cục bộ có tham số được chia sẻ trên đầu vào. Đối với Log-Mel, bộ lọc có thể học các mẫu thay đổi theo thời gian, vùng năng lượng tập trung hoặc cấu trúc phổ lặp lại. Nhiều lớp liên tiếp mở rộng vùng tiếp nhận, cho phép biểu diễn ở tầng sau kết hợp các mẫu cục bộ ở tầng trước.

Một khối CNN thường kết hợp tích chập, hàm kích hoạt và chuẩn hóa. Batch normalization ổn định phân bố kích hoạt trong quá trình tối ưu. Max pooling giảm kích thước đặc trưng và giữ phản hồi nổi bật trong vùng nhỏ. Dropout giảm sự phụ thuộc vào một nhóm nút cụ thể khi huấn luyện. Những thành phần này có thể hỗ trợ tổng quát hóa, nhưng hiệu quả thực tế vẫn phụ thuộc dữ liệu và cấu hình tối ưu.

Đề tài chọn CNN làm mô hình nền vì đầu vào Log-Mel có cấu trúc hai chiều và chi phí suy luận của mạng nhỏ thuận lợi cho ứng dụng cục bộ. Việc chọn CNN không có nghĩa âm thanh chỉ là một bài toán ảnh. Các phép lật trục tần số hoặc xoay ảnh

có thể làm sai ý nghĩa vật lý; nhóm chỉ sử dụng các phép che đặc trưng phù hợp với pipeline đã triển khai.

2.4 Kết nối phần dư và chú ý kênh

Kết nối phần dư đưa đầu vào của một khối đi qua nhánh tắt rồi cộng với đầu ra của nhánh biến đổi. Ý tưởng này cho phép khối học phần hiệu chỉnh so với biểu diễn ban đầu, thay vì luôn phải xây dựng một ánh xạ mới hoàn toàn [2]. Khi số kênh hoặc kích thước không gian thay đổi, nhánh tắt cần phép chiếu để hai tensor có thể cộng được.

$$h_out = \varphi(F(h_in) + P(h_in)) \tag{2.3}$$

Trong công thức (2.3), F là nhánh tích chập, P là ánh xạ đồng nhất hoặc phép chiếu và φ là hàm kích hoạt. Với ResCNN của đề tài, nhánh chính dùng hai tích chập 3 × 3. Các khối giảm kích thước bằng stride 2 và sử dụng nhánh chiếu 1 × 1 khi cần thay đổi số kênh.

Cơ chế Squeeze-and-Excitation (SE) gom thông tin toàn cục của từng kênh, tạo hệ số qua một mạng nhỏ rồi nhân trở lại đặc trưng [3]. Nhờ đó, mô hình có thể điều chỉnh mức đóng góp của các kênh theo đầu vào. Trong đề tài, SE nằm trong khối phần dư. Đây là việc vận dụng một cơ chế đã công bố, không phải một cơ chế chú ý mới do nhóm đề xuất.

Kiến trúc có thêm kết nối và chú ý không bảo đảm tốt hơn mô hình đơn giản. Với dữ liệu giới hạn, mạng nhiều tham số có thể khớp tốt trên train nhưng chưa cải thiện validation hoặc test. Vì vậy, vai trò của ResCNN là một phương án so sánh có giả thuyết rõ ràng, và kết luận phải dựa trên kết quả thực nghiệm.

2.5 Audio Spectrogram Transformer và học chuyển giao

Audio Spectrogram Transformer (AST) áp dụng kiến trúc Transformer trực tiếp lên biểu diễn phổ [1]. Đầu vào được chia thành các patch, mỗi patch được chuyển thành vector và bổ sung thông tin vị trí. Các tầng self-attention học quan hệ giữa những vùng khác nhau trong phổ, từ đó tạo biểu diễn dùng cho phân loại.

$$\text{Attention}(Q,K,V) = \text{softmax}(QK^T / \sqrt{d_k})V \quad (2.4)$$

Công thức (2.4) biểu diễn một đầu chú ý. Q, K và V là các phép chiếu học được từ đầu vào; d_k là chiều vector khóa. Cơ chế này cho phép đầu ra tại một vị trí phụ thuộc các vị trí khác trong chuỗi patch. So với bộ lọc tích chập cục bộ, self-attention có khả năng kết hợp quan hệ xa ngay trong từng tầng nhưng thường tốn bộ nhớ và tính toán hơn.

Nhóm sử dụng checkpoint MIT/ast-finetuned-audioset-10-10-0.4593, thay tầng phân loại để phù hợp bảy nhãn và tinh chỉnh trọng số [4]. Nguồn pretrained giúp mô hình bắt đầu từ biểu diễn âm thanh đã học, thay vì khởi tạo ngẫu nhiên toàn bộ mạng. Tuy nhiên, so sánh AST với CNN huấn luyện từ đầu đồng thời thay đổi kiến trúc, quy mô và lịch sử dữ liệu. Do đó, kết quả chưa tách riêng được đóng góp của self-attention.

Bộ trích xuất AST sử dụng thông số chuẩn hóa đi kèm checkpoint. Áp dụng thống kê Log-Mel của CNN vào nhánh này sẽ làm thay đổi phân bố đầu vào mà mô hình pretrained mong đợi. Đề tài giữ riêng hai quy trình để tránh sự thay thế không tương thích này. Việc trùng nguồn giữa dữ liệu pretraining và UrbanSound8K chưa được kiểm toán đầy đủ, nên đây vẫn là giới hạn của phép so sánh học chuyển giao.

2.6 Tăng cường dữ liệu và hàm mất mát

Tăng cường dữ liệu tạo các biến thể đầu vào trong quá trình huấn luyện để mô hình ít phụ thuộc vào một dạng biểu diễn cố định. Che một vùng thời gian hoặc một nhóm dải Mel buộc mạng tận dụng thông tin còn lại. Hướng này liên quan đến time masking và frequency masking trong SpecAugment [5]. Đề tài sử dụng các thành phần che phổ phù hợp với mã đã chạy, không hiện thực toàn bộ phép time warping của công trình gốc.

Nhánh AST còn dùng dịch tín hiệu, thay đổi mức âm lượng và thêm nhiễu nhẹ trong train. Các biến đổi không được áp dụng khi đánh giá validation và test. Nếu phép tăng cường làm mất hoàn toàn một tiếng động rất ngắn, nhãn có thể không còn

phản ánh nội dung đầu vào. Vì vậy, độ rộng vùng che và cường độ biến đổi cần được giới hạn, thay vì giả định càng mạnh càng tốt.

Hàm mất mát là cross-entropy có trọng số lớp và label smoothing bằng 0,06 trong notebook thực nghiệm. Trọng số lớp được xác định từ train, giúp giảm ảnh hưởng của khác biệt số lượng mẫu. Label smoothing phân phối một phần xác suất mục tiêu sang các lớp còn lại, hạn chế mục tiêu quá cứng. Đây là thành phần tối ưu, không phải phép hiệu chuẩn xác suất sau huấn luyện.

2.7 Các nghiên cứu liên quan và hướng tiếp cận của nhóm

Salamon và Bello khảo sát CNN cùng tăng cường dữ liệu cho phân loại âm thanh môi trường [7]. Công trình cho thấy việc lựa chọn biểu diễn và biến đổi dữ liệu là một phần quan trọng của pipeline. Nhóm kế thừa hướng dùng phổ thời gian–tần số làm đầu vào, đồng thời tổ chức phân tích lỗi theo lớp để tránh chỉ nhìn vào một chỉ số chung.

Walden và cộng sự nghiên cứu phân loại âm thanh phục vụ nhận thức môi trường cho phương tiện tự hành [9]. Bài báo chọn bảy lớp liên quan đến bối cảnh này và công bố accuracy 97,82%. Tập nhãn của bài có air_conditioner, còn đề tài dùng drilling; cách chia dữ liệu và tiền xử lý cũng khác. Con số của bài vì vậy chỉ được nêu để mô tả công trình, không dùng làm mốc kết luận mô hình của nhóm tốt hơn hay kém hơn.

Gong, Chung và Glass đề xuất AST cho phân loại âm thanh dựa trên chú ý [1]. So với việc chỉ học đặc trưng cục bộ bằng tích chập, AST cung cấp một hướng biểu diễn khác và có thể khai thác trọng số pretrained. Nhóm chọn công trình này làm nền tảng cho nhánh học chuyển giao vì đã có mô hình công khai và bộ trích xuất đầu vào đi kèm.

CHƯƠNG 3
DỮ LIỆU VÀ THIẾT KẾ THỰC NGHIỆM

3.1 Nguồn gốc và cấu trúc dữ liệu

UrbanSound8K cung cấp các đoạn âm thanh ngắn tối đa khoảng 4 giây, được lấy từ bản ghi trên Freesound và gắn nhãn theo các nhóm âm thanh đô thị [6], [8]. Metadata chứa tên tệp, fsID, mốc thời gian, mức nổi bật của nguồn âm, fold và nhãn lớp. fsID có ý nghĩa quan trọng vì nhiều đoạn cắt khác nhau có thể xuất phát từ cùng một bản ghi dài.

Khi sử dụng dữ liệu, nhóm giữ liên hệ giữa tệp và metadata thay vì chỉ lưu một ma trận đặc trưng không kèm tên. Điều này cho phép truy ngược một dự đoán sai về tệp cụ thể. Những trường như tên tệp và fsID dùng cho kiểm toán và chia tập, không được đưa vào mạng như đặc trưng phân loại.

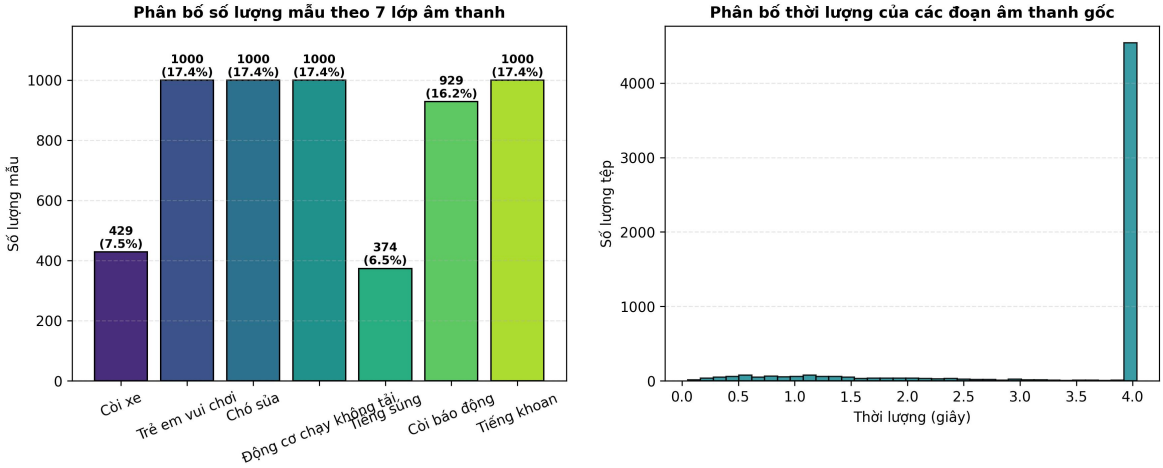
Trang dữ liệu chính thức khuyến nghị giữ mười fold định sẵn và đánh giá chéo đủ mười lượt [8]. Thí nghiệm của khóa luận hiện dùng một lượt test fold 10 để phù hợp phạm vi triển khai đã có. Vì vậy, các bảng trong chương kết quả luôn được diễn giải trong điều kiện của lượt này, không ghi là độ chính xác chung trên bộ UrbanSound8K nguyên bản.

3.2 Lựa chọn bảy lớp và khảo sát ban đầu

Sau khi lọc nhãn, dữ liệu có 5.732 đoạn hợp lệ. Số lượng các lớp không đồng đều: car_horn và gun_shot ít mẫu hơn những lớp có khoảng một nghìn đoạn. Sự khác nhau này khiến accuracy có thể che khuất chất lượng ở nhóm ít mẫu. Nhóm sử dụng macro-F1 làm tiêu chí chính khi chọn checkpoint để mỗi lớp có mức đóng góp ngang nhau trong phép trung bình.

Bảng 3.1 Tập nhãn được sử dụng trong đề tài

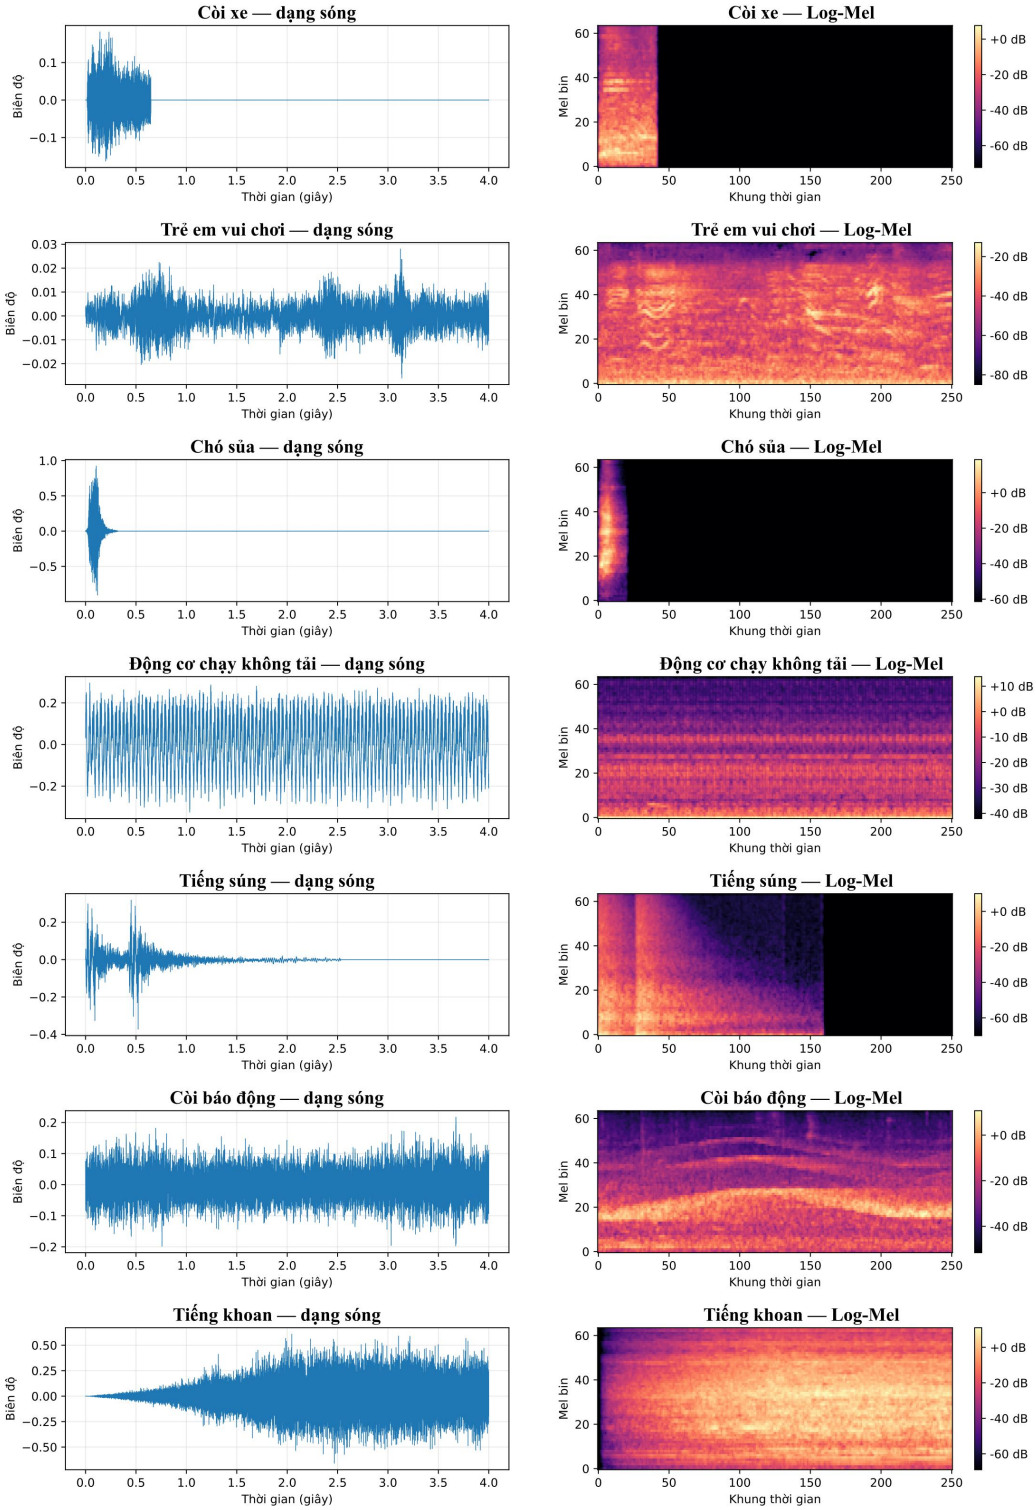
Mã	Nhãn gốc	Tên tiếng Việt
0	car_horn	Còi xe
1	children_playing	Trẻ em vui chơi
2	dog_bark	Chó sủa
3	engine_idling	Động cơ chạy không tải
4	gun_shot	Tiếng súng
5	siren	Còi báo động
6	drilling	Tiếng khoan



Hình 3.1 Phân bố dữ liệu của bảy lớp trước khi chia tập

Nguồn: kết quả thực nghiệm của nhóm.

Hình 3.1 được tạo từ dữ liệu của dự án. Phân bố số mẫu chỉ phản ánh lượng đoạn cắt, không phản ánh đầy đủ số bối cảnh độc lập. Một lớp có nhiều đoạn từ một vài nguồn ghi âm vẫn có thể kém đa dạng hơn lớp có ít đoạn nhưng nhiều nguồn. Đây là lý do nhóm kiểm tra cả số lượng mẫu lẫn quan hệ nguồn ghi âm.



Hình 3.2 Dạng sóng và phổ Log-Mel của các mẫu âm thanh

Nguồn: kết quả thực nghiệm của nhóm.

Hình 3.2 minh họa sự khác nhau giữa quan sát ở miền thời gian và miền thời gian–tần số. Những âm có xung ngắn thường tạo các vùng năng lượng tập trung theo thời

gian; tiếng động cơ có thể kéo dài với cấu trúc lặp. Đây là quan sát định tính trên các mẫu minh họa, chưa phải bằng chứng rằng mọi tệp trong cùng lớp đều có cùng hình dạng phổ.

3.3 Kiểm tra chất lượng và kiểm soát rò rỉ

Nhóm kiểm tra khả năng đọc tệp, dữ liệu tín hiệu hữu hạn và mã băm SHA-256. Báo cáo audit hiện ghi nhận không có tệp lỗi bị loại và không có bản sao trùng hoàn toàn theo SHA-256. Kết quả này chỉ xác nhận hai dạng kiểm tra đã thực hiện; nó không loại trừ trường hợp hai tệp gần giống nhau sau khi thay đổi codec, mức âm lượng hoặc đoạn cắt.

Kiểm tra nguồn cho thấy hai fsID xuất hiện ở nhiều fold trong phần dữ liệu đang sử dụng. Nhóm áp dụng quy tắc ưu tiên test, sau đó validation, cuối cùng train. Nếu nguồn đã nằm trong tập ưu tiên cao hơn, các đoạn cùng nguồn trong tập còn lại bị loại. Lần chia hiện tại loại sáu mẫu khỏi train và không loại mẫu khỏi validation.

Việc loại nguồn giao nhau làm giảm một dạng rò rỉ trực tiếp giữa các tập. Tuy vậy, bản ghi có thể cùng bối cảnh nhưng khác fsID, và pretraining của AST sử dụng một kho dữ liệu khác chưa được kiểm toán giao nhau. Báo cáo vì thế dùng cách diễn đạt "kiểm soát giao nhau theo fsID và trùng tệp", thay vì khẳng định đã loại bỏ mọi dạng rò rỉ dữ liệu.

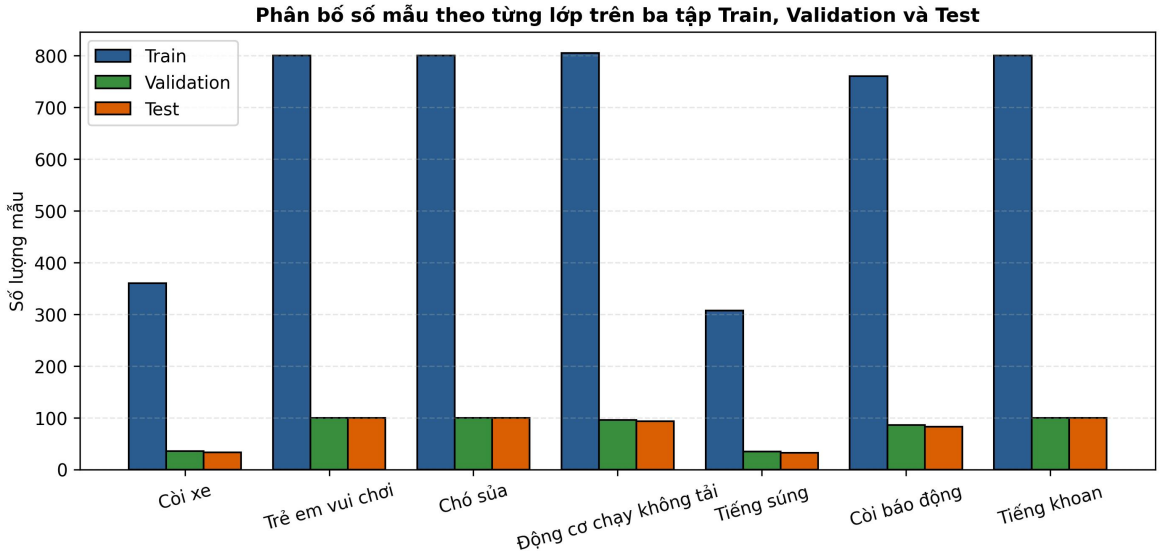
3.4 Chia tập huấn luyện và đánh giá

Train gồm các fold 2 đến 9 sau khi áp dụng quy tắc loại nguồn trùng. Validation là fold 1, dùng để chọn checkpoint và tìm trọng số ensemble. Test là fold 10, dùng để báo cáo kết quả cuối của cấu hình đang xét. Cả ba mô hình sử dụng cùng danh sách mẫu của mỗi tập để hạn chế sai lệch do dữ liệu đánh giá khác nhau.

Bảng 3.2 Phân bố số mẫu theo lớp sau khi chia tập và loại nguồn trùng

Lớp	Train	Validation	Test
Còi xe	360	36	33
Trẻ em vui chơi	800	100	100
Chó sủa	800	100	100
Động cơ chạy không tải	805	96	93
Tiếng súng	307	35	32
Còi báo động	760	86	83
Tiếng khoan	800	100	100
Tổng	4.632	553	541

Tổng cộng có 4.632 mẫu train, 553 mẫu validation và 541 mẫu test. Tổng sau lọc là 5.726, thấp hơn số mẫu hợp lệ ban đầu sáu đoạn. Mọi thống kê dùng cho chuẩn hóa CNN và trọng số lớp đều được tính trên train. Validation và test chỉ được biến đổi bằng các tham số đã xác định, không được dùng để ước lượng lại thống kê.



Hình 3.3 Phân bố lớp trên train validation và test

Nguồn: kết quả thực nghiệm của nhóm.

Tập test có 33 mẫu còi xe và 32 mẫu tiếng súng. Khi số mẫu nhỏ, chỉ một vài dự đoán thay đổi cũng làm precision hoặc recall dịch chuyển đáng kể. Vì vậy, một lớp

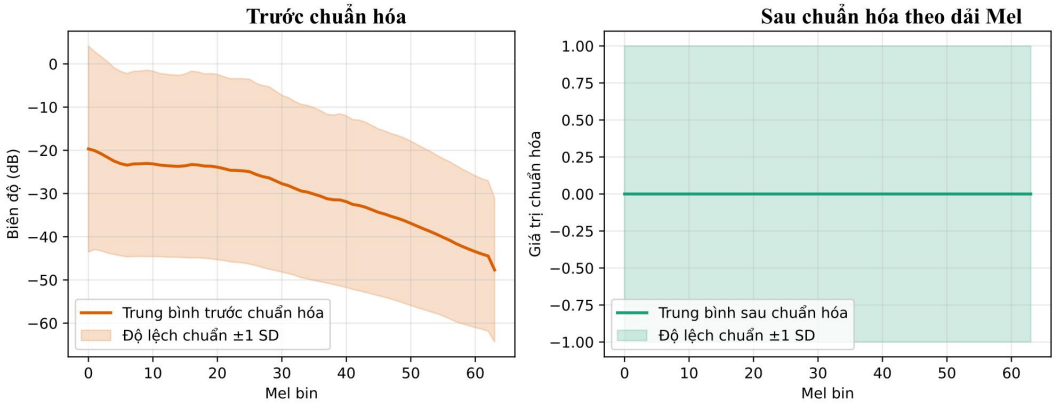
đạt 100% trên tập này chưa đủ để kết luận mô hình giải quyết tốt mọi tình huống thực tế của lớp đó. Chương 5 phân tích chỉ số theo lớp cùng số mẫu để tránh diễn giải quá mức.

3.5 Tiền xử lý cho CNN

Tín hiệu được chuyển về mono, resample về 16 kHz, sau đó cắt giữa nếu dài hơn 4 giây hoặc đệm thêm giá trị không nếu ngắn hơn. Chuỗi này tạo đầu vào có số mẫu cố định và giảm sự khác nhau về định dạng tệp. Đệm không chỉ bổ sung phần thiếu, không tạo thêm nội dung âm thanh mới.

Log-Mel được trích xuất từ phổ công suất với 64 dải, miền tần số từ 20 Hz đến 8 kHz. Trong notebook đã chạy, chuẩn hóa được thực hiện riêng cho từng dải Mel. Trung bình và độ lệch chuẩn được tính trên tập train theo các chiều mẫu và thời gian. Giá trị độ lệch chuẩn được chặn dưới để tránh phép chia không ổn định ở những dải ít biến thiên.

$$Z(b,t) = [L(b,t) - \mu_train(b)] / \max(\sigma_train(b), \varepsilon) \qquad (3.1)$$



Hình 3.4 Phân bố đặc trưng trước và sau chuẩn hóa theo dải Mel

Nguồn: kết quả thực nghiệm của nhóm.

Chuẩn hóa theo dải giúp giảm chênh lệch thang đo giữa các vùng tần số. Các tham số này được lưu trong cnn_norm_fold10.npz để ứng dụng suy luận có thể sử dụng lại. Tệp stats_fold10.json của phiên bản mã khác chứa thống kê toàn cục; hai cách chuẩn hóa không được hoán đổi tùy ý khi nạp checkpoint. Việc khớp phiên bản tiền xử lý với phiên bản huấn luyện là một điều kiện của tái lập.

3.6 Tiền xử lý và tăng cường dữ liệu cho AST

Nhánh AST sử dụng ASTFeatureExtractor của checkpoint pretrained. Tín hiệu vẫn ở 16 kHz và được đưa qua bộ trích xuất có 128 dải Mel, chiều thời gian tối đa 1.024. Giá trị trung bình −4,2677393 và độ lệch chuẩn 4,5689974 là thông số của bộ xử lý đã lưu. Quy ước chuẩn hóa phải được thực hiện bởi bộ trích xuất tương ứng, không tự thay bằng công thức z-score của CNN.

Trong train, tín hiệu AST được dịch tối đa 1.200 mẫu theo hai hướng, tương đương khoảng 75 ms ở 16 kHz. Mức biên độ thay đổi trong khoảng ±3 dB; nhiễu Gaussian có độ lệch chuẩn 0,002 được thêm với xác suất 0,3. Sau đó, đầu vào được giới hạn về miền biên độ hợp lệ và che một số khung thời gian, dải tần trên đặc trưng. Validation và test không dùng những biến đổi ngẫu nhiên này.

Các phép biến đổi của CNN và AST không hoàn toàn giống nhau. Đây là thiết kế gắn với từng pipeline, nhưng cũng làm phép so sánh thay đổi nhiều yếu tố cùng lúc. Để đo riêng tác dụng của kiến trúc, cần thí nghiệm đối chứng với các tổ hợp tăng cường và ngân sách huấn luyện được kiểm soát chặt hơn. Thí nghiệm đó chưa nằm trong kết quả được báo cáo ở đây.

3.7 Chỉ số và nguyên tắc đánh giá

Accuracy là tỉ lệ dự đoán đúng trong toàn bộ tập kiểm tra. Precision của một lớp cho biết trong các mẫu được dự đoán là lớp đó, bao nhiêu mẫu đúng; recall cho biết trong các mẫu thực sự thuộc lớp đó, bao nhiêu mẫu được nhận ra. F1 là trung bình điều hòa của precision và recall. Macro-F1 lấy trung bình F1 của từng lớp mà không tăng trọng số cho lớp đông mẫu.

$$\text{Accuracy} = N_{\text{đúng}}/N;\ P_c = TP_c/(TP_c+FP_c);\ R_c = TP_c/(TP_c+FN_c) \quad (3.2)$$

$$F1_c = 2P_cR_c/(P_c+R_c);\ \text{Macro-F1} = (1/C)\Sigma_c F1_c \quad (3.3)$$

Weighted-F1 là trung bình F1 có trọng số theo số mẫu từng lớp. Báo cáo giữ cả macro-F1 và weighted-F1 để thấy ảnh hưởng của phân bố nhãn. Khi mẫu của một

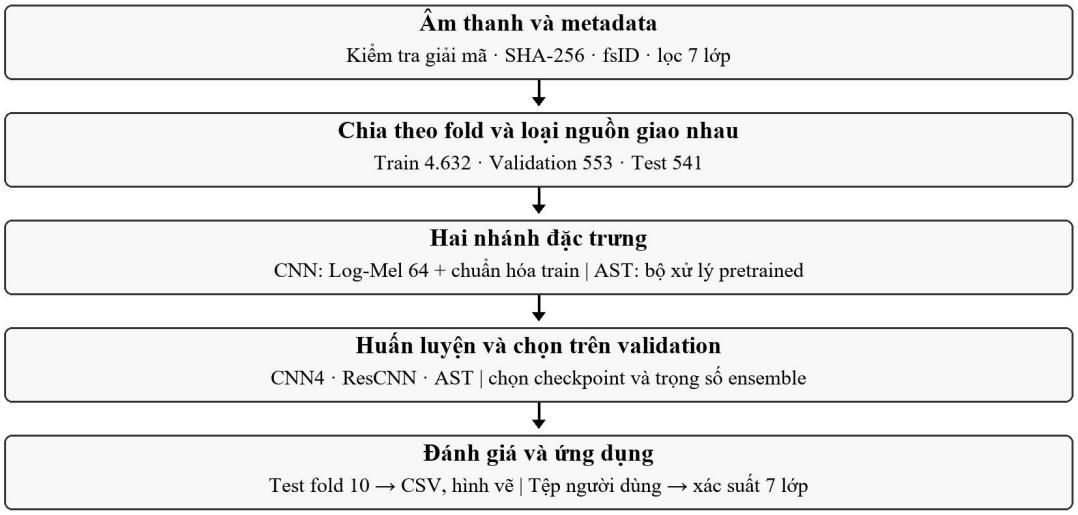
lớp ít, macro-F1 vẫn cho lớp đó trọng số bằng lớp đông. Cách tính này phù hợp mục tiêu so sánh chất lượng cân bằng, nhưng không thay thế việc xem ma trận nhầm lẫn.

ROC được xây dựng theo one-vs-rest với xác suất của từng lớp. Chỉ số này mô tả khả năng xếp hạng điểm khi thay đổi ngưỡng, trong khi nhãn cuối cùng của hệ thống vẫn lấy argmax. PCA được dùng để xem biểu diễn hai chiều ở mức minh họa. Khoảng cách trên hình PCA không phải một chỉ số kiểm định chất lượng phân loại và không được dùng để chứng minh quan hệ nhân quả.

CHƯƠNG 4
PHƯƠNG PHÁP VÀ HIỆN THỰC HỆ THỐNG

4.1 Kiến trúc tổng thể

Hệ thống được tổ chức thành hai luồng. Luồng thực nghiệm nhận metadata và âm thanh, kiểm tra dữ liệu, chia tập, tạo đặc trưng, huấn luyện và lưu kết quả. Luồng ứng dụng nhận tệp từ người dùng, thực hiện tiền xử lý tương ứng, nạp checkpoint và trả dự đoán. Hai luồng cùng sử dụng thứ tự nhãn đã cố định để tránh sai lệch khi giải mã vector đầu ra.



Hình 4.1 Luồng xử lý dữ liệu huấn luyện và suy luận

Nguồn: nhóm xây dựng theo notebook thực nghiệm.

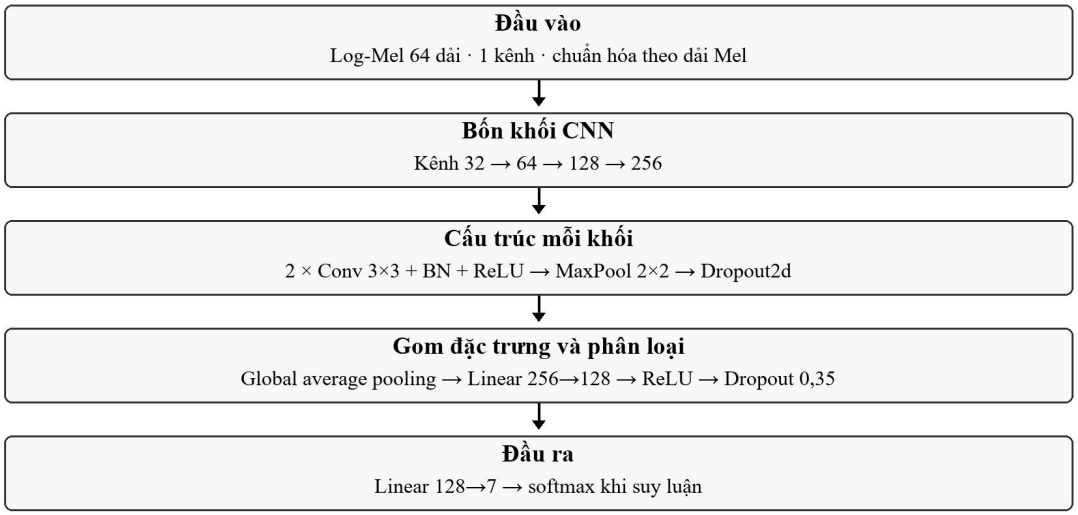
Các tệp cấu hình, thống kê và checkpoint là một bộ thành phần đi cùng nhau. Chỉ thay checkpoint mà giữ bộ xử lý đặc trưng của một lần chạy khác có thể vẫn tạo được đầu ra nhưng sai ý nghĩa. Vì vậy, mô tả triển khai cần nêu rõ đường dẫn và phiên bản của từng thành phần, không chỉ tên mô hình.

4.2 Mô hình CNN4

CNN4 trong notebook thực nghiệm gồm bốn khối với số kênh lần lượt 32, 64, 128 và 256. Mỗi khối có hai tích chập 3 × 3, batch normalization và ReLU, sau đó là max pooling 2 × 2 và dropout hai chiều. Xác suất dropout ở bốn khối lần lượt là

0,10; 0,15; 0,20 và 0,25. Mạng giảm dần kích thước theo thời gian và tần số trước khi gom đặc trưng toàn cục.

Sau bốn khối, adaptive average pooling đưa mỗi kênh về một giá trị. Tầng phân loại lần lượt có 256 đầu vào, 128 nút ẩn, ReLU, dropout 0,35 và bảy đầu ra. Cách dùng pooling toàn cục làm giảm số tham số so với trải phẳng toàn bộ bản đồ đặc trưng. Tổng số tham số của mô hình trong bảng benchmark là khoảng 1,206 triệu.



Hình 4.2 Kiến trúc CNN4 dùng trong notebook thực nghiệm

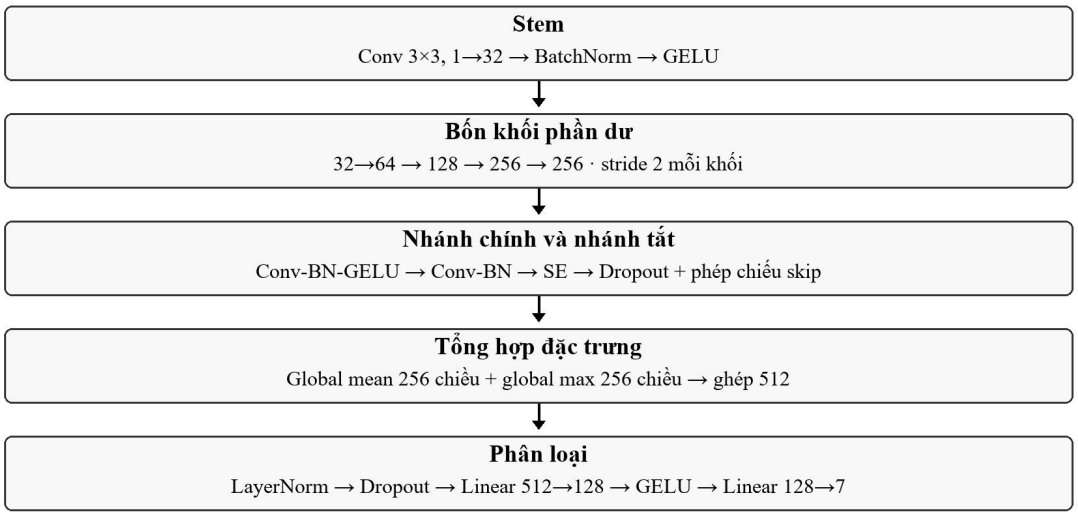
Nguồn: nhóm xây dựng theo notebook thực nghiệm.

Mô hình này được xây dựng như một phương án nền theo hướng CNN trên phổ, có tham khảo bối cảnh phân loại âm thanh của Walden và cộng sự [9]. Tuy nhiên, số lớp tích chập trong khối, đầu vào và tập nhãn không phải một bản tái lập chính xác bài báo. Báo cáo gọi mô hình là CNN4 của dự án, không gắn kết quả của mô hình này với accuracy đã công bố trong công trình gốc.

4.3 Mô hình ResCNN có chú ý kênh

ResCNN bắt đầu bằng tích chập 3 × 3 từ một kênh vào 32 kênh, batch normalization và GELU. Tiếp theo là bốn khối phần dư với các cặp số kênh 32→64, 64→128, 128→256 và 256→256. Mỗi khối dùng stride 2 ở tích chập đầu để giảm kích thước. Nhánh tắt thực hiện phép chiếu khi số kênh hoặc độ phân giải thay đổi.

Trong nhánh chính, đặc trưng sau hai tích chập được nhân với hệ số chú ý kênh SE rồi đi qua dropout trước khi cộng nhánh tắt. Hệ số được tạo bằng pooling trung bình toàn cục và hai tích chập 1 × 1 có tầng giữa thu hẹp số kênh. Sigmoid đưa hệ số về khoảng từ 0 đến 1. Cấu trúc này cho phép phản hồi của mỗi kênh được điều chỉnh theo nội dung mẫu.



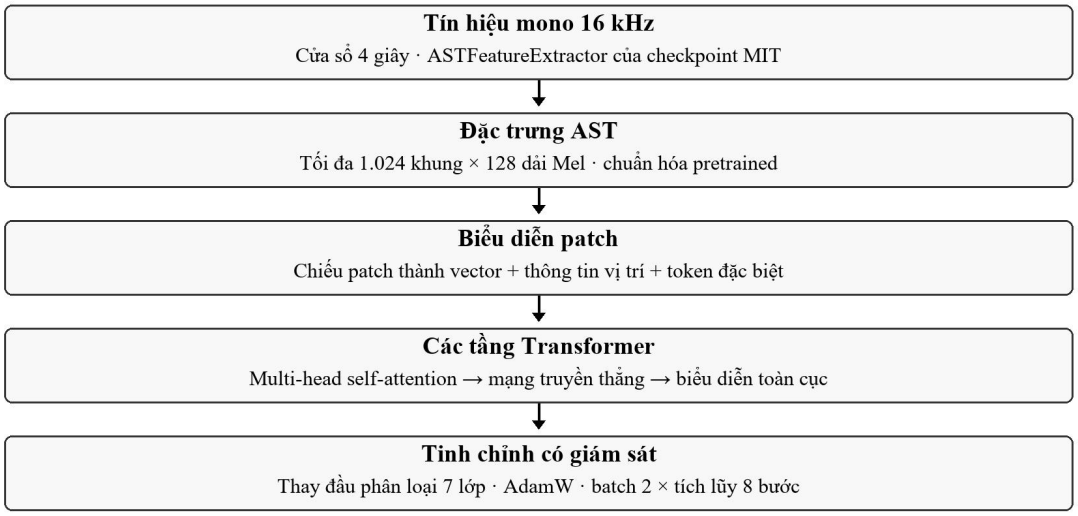
Hình 4.3 Khối phần dư với chú ý kênh và tầng phân loại ResCNN

Nguồn: nhóm xây dựng theo notebook thực nghiệm.

Đầu ra của khối cuối được tổng hợp bằng cả trung bình và cực đại theo hai chiều không gian. Hai vector 256 chiều được ghép thành vector 512 chiều, sau đó đi qua LayerNorm, dropout, tầng 128 nút và tầng phân loại bảy lớp. Tổng số tham số khoảng 2,560 triệu, lớn hơn CNN4 nhưng nhỏ hơn nhiều so với AST. Kết quả ở chương sau cho phép kiểm tra liệu độ phức tạp bổ sung này có hữu ích trong lần chia hiện tại hay không.

4.4 Tinh chỉnh AST

AST được khởi tạo từ checkpoint công khai của MIT [4]. Tầng đầu ra pretrained được thay cho bảy lớp theo thứ tự nhãn của dự án. Việc thay tầng này tạo ra tham số mới ở đầu phân loại, trong khi phần biểu diễn còn lại bắt đầu từ trọng số đã học trước. Mô hình được tinh chỉnh có giám sát trên tập train của đề tài.



Hình 4.4 Quy trình đưa phổ vào AST và tinh chỉnh cho bảy lớp

Nguồn: nhóm xây dựng theo notebook thực nghiệm.

Batch vật lý của AST bằng 2 và tích lũy gradient qua 8 bước, tạo batch hiệu dụng danh nghĩa bằng 16. Với bộ nhớ GPU giới hạn, cách này giảm lượng kích hoạt cần giữ ở mỗi lượt so với batch vật lý 16. Gradient checkpointing được bật để đổi thêm tính toán lấy bộ nhớ. AMP dùng độ chính xác hỗn hợp trong các phép tính phù hợp khi chạy trên CUDA.

Tốc độ học cơ sở của AST là 10^{-5}. Notebook dùng warm-up trong khoảng 10% tổng bước tối ưu rồi giảm theo cosine. Cấu hình này khác với một số tệp mã rời trong thư mục, nên thông số báo cáo được lấy từ cell đã chạy. Mô hình có khoảng 86,194 triệu tham số và checkpoint khoảng 328,887 MB theo phép đo đã lưu.

4.5 Huấn luyện và lựa chọn checkpoint

Cả CNN4 và ResCNN dùng AdamW, tốc độ học ban đầu 8×10^{-4} và weight decay 5×10^{-4}. Số epoch tối đa là 45 đối với CNN và 12 đối với AST, patience bằng 10. Notebook đặt seed 42 cho các nguồn ngẫu nhiên liên quan. Seed hỗ trợ tái lập nhưng không bảo đảm kết quả bitwise giống nhau giữa mọi phiên bản thư viện hoặc loại GPU.

Bảng 4.1 Cấu hình huấn luyện trong notebook đã chạy

Thông số	**CNN4 và ResCNN**	**AST**
Đầu vào	Log-Mel 64 dải	ASTFeatureExtractor 128 dải
Tần số và cửa sổ	16 kHz; 4 giây	16 kHz; 4 giây
Batch vật lý	16	2
Tích lũy gradient	1 bước	8 bước
Epoch tối đa	45	12
Optimizer	AdamW	AdamW
Tốc độ học ban đầu	0,0008	0,00001
Weight decay	0,0005	0,0005
Lịch tốc độ học	Warm-up 10% + cosine	Warm-up 10% + cosine
Label smoothing	0,06	0,06
Patience	10	10
Seed	42	42
Chọn checkpoint	Validation macro-F1	Validation macro-F1

Sau mỗi epoch, mô hình được đánh giá trên validation. Checkpoint tốt nhất được chọn theo validation macro-F1. Train loss và các chỉ số validation được ghi vào CSV để xem quá trình hội tụ. Không chọn checkpoint bằng test loss hoặc test accuracy. Sau khi chọn mô hình, tập test được dùng để tạo bảng so sánh và các phân tích lỗi.

Trọng số lớp trong cross-entropy được tính từ số lượng nhãn train. Label smoothing bằng 0,06 được dùng đồng nhất trong hàm huấn luyện của notebook. Nhóm lưu riêng đường cong loss, accuracy và macro-F1 vì chúng phản ánh các khía cạnh khác nhau: loss nhạy với phân bố xác suất, accuracy phản ánh số nhãn đúng và macro-F1 nhấn mạnh sự cân bằng theo lớp.

4.6 Ensemble xác suất

Ensemble kết hợp vector xác suất của ba mô hình bằng tổng có trọng số không âm, với tổng trọng số bằng 1. Tên lớp và thứ tự các mẫu phải khớp giữa ba nguồn xác suất trước khi cộng. Nếu chỉ lấy trung bình các cột không cùng thứ tự nhãn, phép kết hợp không còn ý nghĩa dù chương trình vẫn chạy.

$$p_ens(c|x) = \Sigma_m\ w_m\ p_m(c|x),\ \ w_m \geq 0,\ \ \Sigma_m\ w_m = 1 \qquad (4.1)$$

Notebook duyệt các tổ hợp trọng số trên lưới validation rồi chọn macro-F1 cao nhất. Bước của trọng số thứ hai phụ thuộc phần còn lại sau trọng số thứ nhất, nên không phải mọi trọng số đều có khoảng cách cố định 0,1. Khi lưu phương án kết hợp, cần xuất đồng thời bộ trọng số tối ưu và thứ tự mô hình. Hai thông tin này xác định chính xác phép cộng xác suất và cần đi cùng checkpoint khi chuyển sang ứng dụng.

Trung bình đều trong ứng dụng khi thiếu tệp ensemble.json là một phương án demo riêng. Nó không bảo đảm tái tạo ensemble được tối ưu trong notebook. Do vậy, bảng kết quả ensemble của chương 5 chỉ gắn với xác suất đã tổng hợp của lần chạy thực nghiệm. Khi đóng gói một bản phát hành tái lập, cần xuất thêm trọng số và thứ tự model_keys của lần chạy đó.

4.7 Hiện thực ứng dụng minh họa

Ứng dụng dùng Gradio để cung cấp giao diện tải tệp hoặc ghi âm, chọn mô hình và chọn thiết bị CPU/GPU. Kết quả gồm nhãn dự đoán, xác suất của bảy lớp và thông tin xử lý. Waveform cùng Log-Mel giúp người dùng quan sát tín hiệu thay vì chỉ nhìn một nhãn. Lịch sử dự đoán được trình bày trong giao diện để thuận tiện thử nhiều tệp liên tiếp.

Các thành phần chính được tách thành mã suy luận, giao diện và cấu hình. app.py là điểm vào; src/app_ui.py xây dựng tương tác; src/engine.py chứa phần xử lý và nạp mô hình. Checkpoint được tìm trong outputs/checkpoints, cấu hình AST và nhãn nằm trong configs. Ứng dụng giữ mô hình trong bộ nhớ để giảm thời gian nạp lại giữa các lần dự đoán.

Tệp rỗng, tín hiệu không hữu hạn, im lặng hoặc dài quá giới hạn được xử lý bằng thông báo lỗi. Ngưỡng demo 0,60 dùng để hiển thị trạng thái chưa chắc chắn khi xác suất cực đại thấp. Ngưỡng này chưa được đánh giá trên một tập ngoài lớp; một giá trị softmax lớn vẫn có thể xuất hiện ở âm thanh không thuộc bảy nhãn. Vì vậy, trạng thái này không được coi là một bộ phát hiện unknown đã kiểm chứng.

4.8 Khả năng tái lập và quản lý kết quả

Nhóm tổ chức đầu ra theo dữ liệu, nhật ký huấn luyện, checkpoint, chỉ số và hình vẽ. CSV cho phép dựng lại bảng và biểu đồ mà không cần huấn luyện lại. Notebook có đầu ra giúp kiểm tra môi trường và diễn biến epoch. Khi chuyển sang máy Windows, cần giữ cùng thứ tự nhãn và bộ tiền xử lý phù hợp checkpoint.

Một điểm còn hạn chế là cấu hình trong notebook đã chạy và một số cấu hình rời chưa đồng nhất. Ví dụ, notebook dùng 45 epoch CNN, batch AST 2 và chuẩn hóa theo dải Mel; một cấu hình rời vẫn ghi 60 epoch, batch AST 1 và thống kê toàn cục. Phần thực nghiệm của khóa luận lấy notebook cùng CSV làm căn cứ. Những giá trị ở phiên bản rời không được trộn vào bảng thông số huấn luyện.

Để tái lập chính xác hơn, gói bàn giao cần được khóa theo một manifest gồm mã nguồn, phiên bản thư viện, checksum checkpoint, danh sách mẫu và trọng số ensemble. Đây là yêu cầu kỹ thuật rút ra từ quá trình đối chiếu, đồng thời là một phần công việc hoàn thiện hệ thống. Chưa có cơ sở để khẳng định mọi phép chạy từ các script rời sẽ tái tạo toàn bộ số liệu đã lưu.

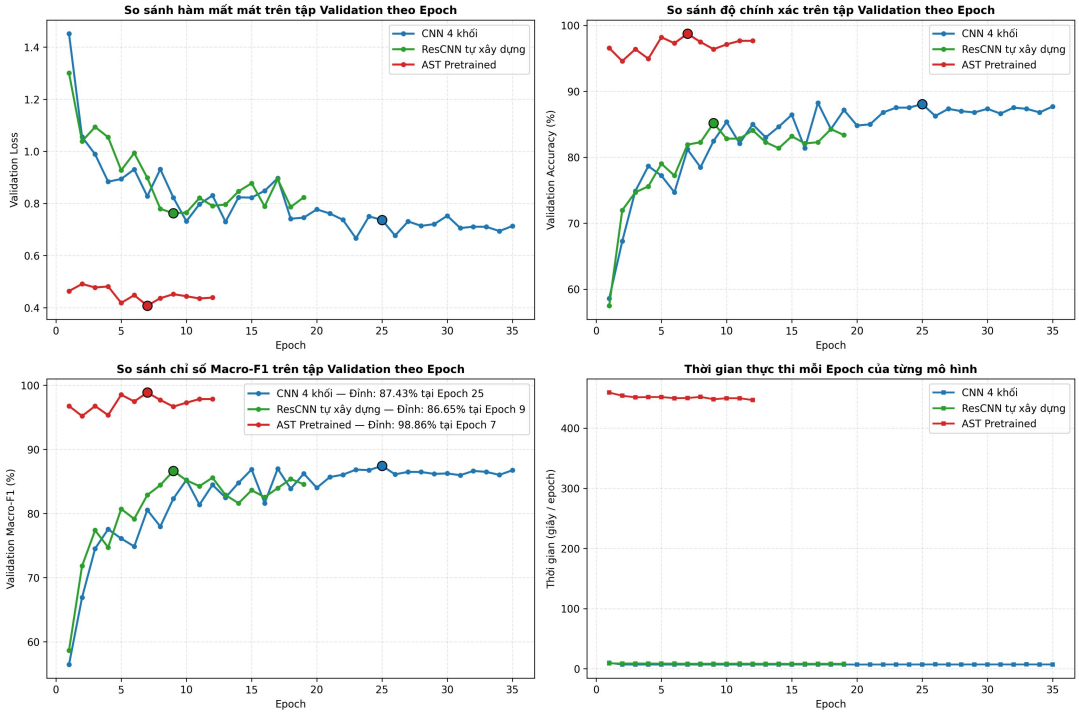
CHƯƠNG 5
THỰC NGHIỆM VÀ ĐÁNH GIÁ

5.1 Môi trường và căn cứ số liệu

Đầu ra notebook ghi nhận GPU Tesla T4, PyTorch 2.11.0+cu128 và thiết bị cuda:0. Thông tin này được lấy từ nhật ký chạy, không suy ra từ nhãn cấu hình notebook. Các bảng chính của chương được tổng hợp từ test_summary_metrics.csv, per_class_detailed_metrics.csv và benchmark_fps_stability_accuracy.csv. Các đường cong lấy từ ba tệp history trong outputs/logs.

Các kết quả trong chương được lấy từ lần chạy notebook đã lưu. Dữ liệu test gồm 541 đoạn sau quá trình chia tập đã mô tả ở chương 3. Thực nghiệm sử dụng một seed và một test fold, vì vậy chưa có độ lệch chuẩn qua nhiều lần huấn luyện độc lập. Các mức chênh lệch được phân tích theo số liệu quan sát, chưa phải kết luận từ kiểm định ý nghĩa thống kê.

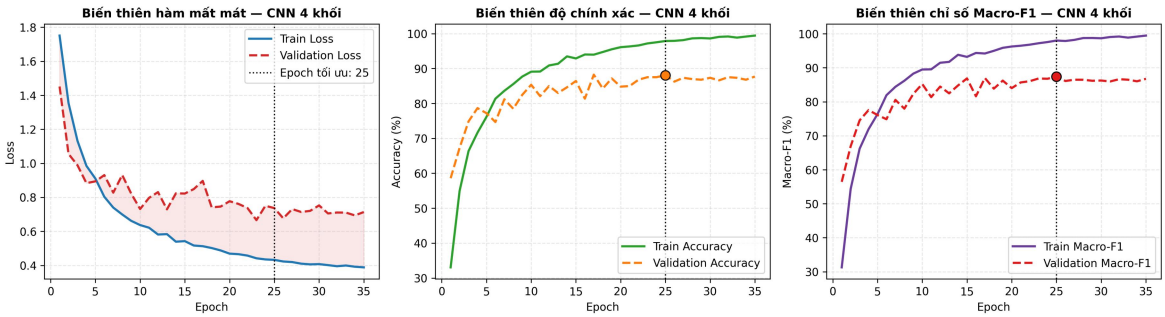
5.2 Quá trình học của các mô hình



Hình 5.1 So sánh diễn biến huấn luyện của CNN4 ResCNN và AST

Nguồn: kết quả thực nghiệm của nhóm.

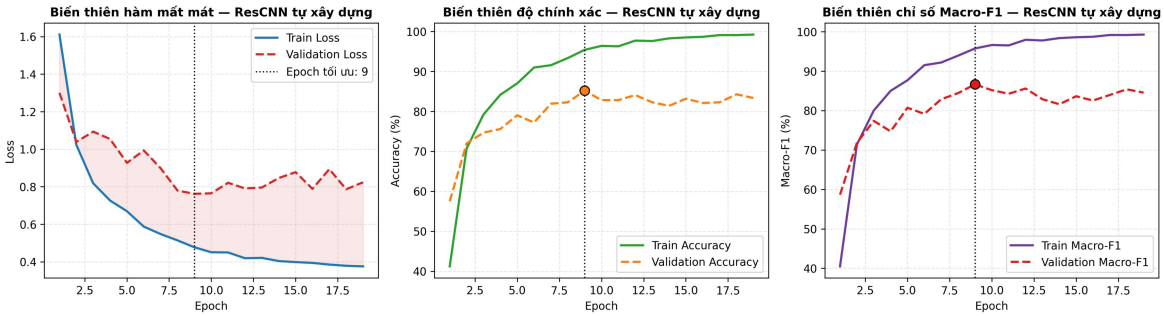
Hình 5.1 cho phép quan sát đồng thời tốc độ giảm loss và thay đổi chỉ số validation. CNN học từ đầu cần nhiều epoch để hình thành biểu diễn thích hợp. AST bắt đầu từ trọng số pretrained nên có thể đạt mức validation cao sớm hơn. Tuy vậy, số epoch giữa các mô hình không tương đương về chi phí: một epoch AST mất nhiều thời gian hơn do mô hình lớn và tiền xử lý đầu vào khác.



Hình 5.2 Đường cong học của CNN4

Nguồn: kết quả thực nghiệm của nhóm.

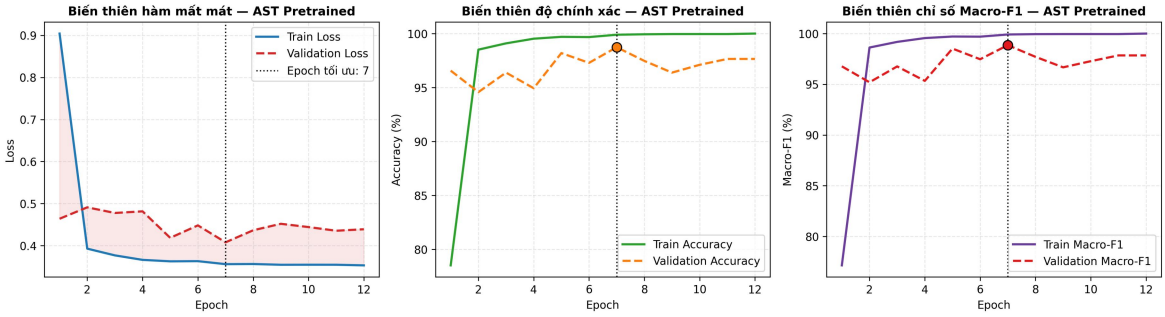
CNN4 đạt validation macro-F1 tốt nhất 87,43% trong bảng tổng hợp. Khoảng cách train–validation trung bình về accuracy trong tệp stability_metrics.csv là khoảng 11,94 điểm phần trăm. Chênh lệch cho thấy việc khớp train tốt hơn chưa chuyển hoàn toàn sang validation. Nhận xét này cần được đọc cùng quá trình tăng cường dữ liệu vì phép đo train trong lúc huấn luyện chịu các biến đổi ngẫu nhiên mà validation không có.



Hình 5.3 Đường cong học của ResCNN

Nguồn: kết quả thực nghiệm của nhóm.

ResCNN có validation macro-F1 86,65%, thấp hơn CNN4 dù nhiều tham số hơn. Khoảng cách train–validation trung bình của mô hình khoảng 15,88 điểm phần trăm. Trong thiết lập này, cấu trúc phần dư và chú ý kênh chưa đem lại lợi ích vượt mô hình nền. Chưa thể từ kết quả đó kết luận riêng SE là nguyên nhân làm giảm chất lượng vì chưa có thí nghiệm bỏ SE trong cùng kiến trúc.



Hình 5.4 Đường cong học của AST pretrained

Nguồn: kết quả thực nghiệm của nhóm.

AST đạt validation macro-F1 98,86% sau khi làm tròn hai chữ số. Nhật ký ghi best_epoch bằng 7. Tuy nhiên, macro-F1 test chỉ đạt 91,88%, thấp hơn validation gần 6,98 điểm phần trăm. Sự chênh lệch này cho thấy cần đánh giá trên dữ liệu giữ

lại, ngay cả khi đường cong validation đã cao. Một fold validation thuận lợi không đủ thay thế nhiều fold kiểm tra độc lập.

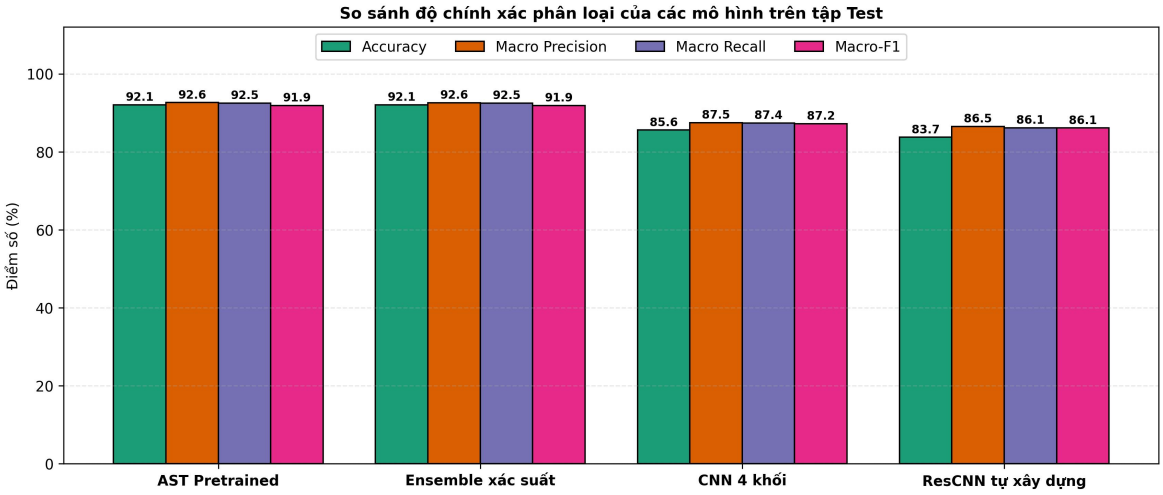
5.3 Kết quả tổng thể trên tập kiểm tra

Bảng 5.1 So sánh các mô hình trên test fold 10 với 541 mẫu

Mô hình	Val F1	Test Acc	Macro P	Macro R	Macro F1	W. F1
AST	98,86	92,05	92,61	92,51	91,88	91,97
ENSEMBLE	98,86	92,05	92,56	92,51	91,86	91,96
CNN4	87,43	85,58	87,47	87,40	87,23	85,53
RESCNN	86,65	83,73	86,49	86,14	86,11	83,85

Các chỉ số trong bảng tính theo %. P: precision; R: recall; W. F1: weighted-F1.

AST đạt accuracy 92,05%, cao hơn CNN4 khoảng 6,47 điểm phần trăm và ResCNN khoảng 8,32 điểm phần trăm. Macro-F1 của AST là 91,88%, cao hơn CNN4 khoảng 4,65 điểm và ResCNN khoảng 5,77 điểm. Hai chỉ số cùng cải thiện, cho thấy ưu thế không chỉ nằm ở việc tăng số mẫu đúng ở lớp đông.



Hình 5.5 Accuracy và macro-F1 trên tập kiểm tra

Nguồn: kết quả thực nghiệm của nhóm.

Accuracy của AST tương ứng 498 dự đoán đúng trên 541 mẫu. CNN4 đúng 463 mẫu và ResCNN đúng 453 mẫu. Chuyển tỉ lệ thành số lượng giúp thấy rõ quy mô của khác biệt. Tuy nhiên, các dự đoán trên những đoạn cùng nguồn có thể tương

quan; không nên xem 541 đoạn là 541 phép thử độc lập hoàn toàn để suy ra một khoảng tin cậy quá lạc quan.

Ensemble đạt accuracy bằng AST nhưng macro-F1 91,86%, thấp hơn AST khoảng 0,019 điểm phần trăm. Validation macro-F1 của ensemble cao hơn AST khoảng 0,0028 điểm phần trăm, một khoảng rất nhỏ. Lợi ích trên validation chưa chuyển thành lợi ích trên test. Vì chưa có lặp nhiều seed và fold, báo cáo không diễn giải mức chênh nhỏ này như một khác biệt có ý nghĩa thống kê.

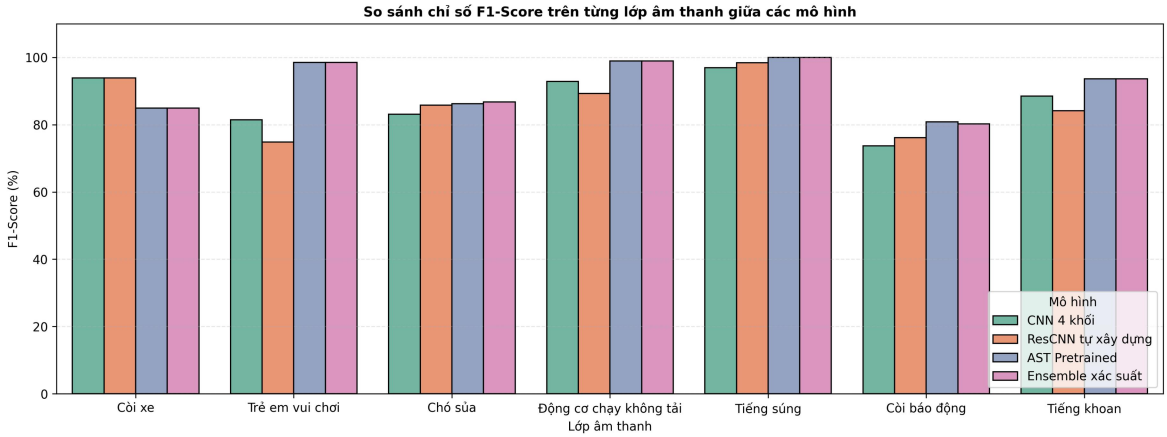
Trong phạm vi số liệu hiện có, AST là mô hình đơn có chất lượng tốt nhất trên test. Kết luận này là kết quả mô tả sau đánh giá. Nếu triển khai một quy trình lựa chọn hoàn toàn theo validation, ensemble vẫn là ứng viên có điểm validation cao nhất, nhưng phải cân nhắc chi phí và độ tin cậy của mức cải thiện quá nhỏ. Không nên thay đổi nguyên tắc lựa chọn sau khi đã nhìn test rồi gọi đó là đánh giá độc lập.

5.4 Phân tích theo từng lớp

Bảng 5.2 Precision recall và F1 của AST theo lớp trên test fold 10

Lớp	Số mẫu	Precision (%)	Recall (%)	F1 (%)
Còi xe	33	77,50	93,94	84,93
Trẻ em vui chơi	100	97,09	100,00	98,52
Chó sủa	100	77,60	97,00	86,22
Động cơ chạy không tải	93	98,92	98,92	98,92
Tiếng súng	32	100,00	100,00	100,00
Còi báo động	83	98,28	68,67	80,85
Tiếng khoan	100	98,89	89,00	93,68

AST nhận diện tốt trẻ em vui chơi, động cơ chạy không tải và tiếng khoan trong lần chia này. Tiếng súng có precision, recall và F1 đều 100% trên 32 mẫu. Đây là kết quả trên tập test giới hạn, chưa chứng minh khả năng nhận diện các tiếng nổ khác bối cảnh hoặc phân biệt tiếng súng với mọi loại xung âm ngoài đời.



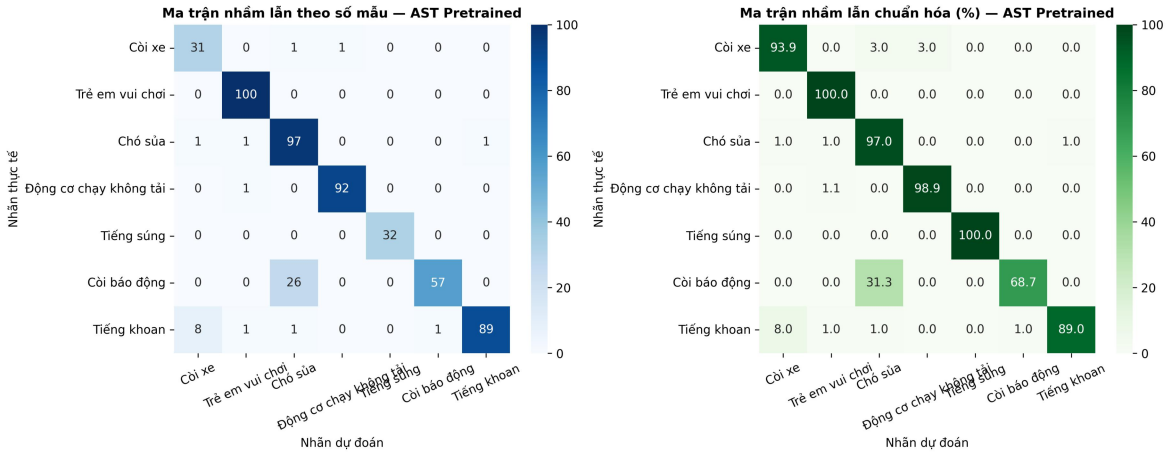
Hình 5.6 So sánh F1 của bốn phương án theo lớp

Nguồn: kết quả thực nghiệm của nhóm.

Lớp còi báo động có precision 98,28% nhưng recall chỉ 68,67%. Hai giá trị cho thấy khi AST đã dự đoán còi báo động thì thường đúng, song nhiều mẫu thực sự thuộc lớp này bị bỏ sót. Ngược lại, chó sủa có recall 97,00% nhưng precision 77,60%, phù hợp với tình trạng một số âm khác bị nhận nhầm thành chó sủa. Hai loại sai số này sẽ dẫn đến yêu cầu cải thiện khác nhau.

Còi xe có recall 93,94% nhưng precision 77,50%. Một phần sai số đến từ các mẫu tiếng khoan bị gán thành còi xe. Điều đó giải thích vì sao một lớp có recall cao chưa chắc đạt F1 cao. Báo cáo dùng cả ba chỉ số theo lớp để phân biệt khả năng tìm đúng và mức độ dự đoán nhầm.

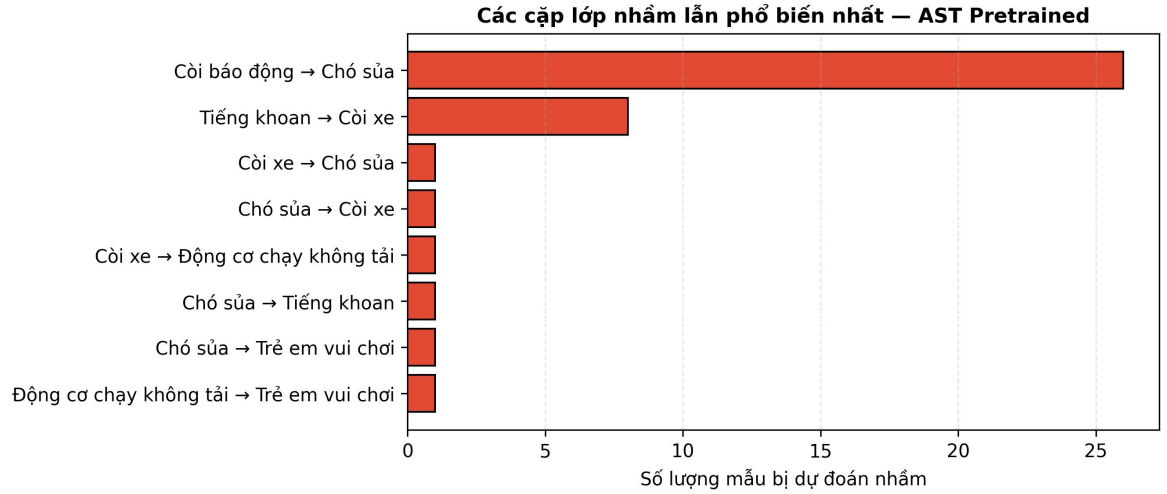
5.5 Ma trận nhầm lẫn và các lỗi nổi bật



Hình 5.7 Ma trận nhầm lẫn của AST

Nguồn: kết quả thực nghiệm của nhóm.

Theo top_confusion_errors.csv, cặp nhầm lẫn lớn nhất của mô hình đơn đang phân tích là còi báo động thành chó sủa, với 26 mẫu. Nhóm thứ hai là tiếng khoan thành còi xe, với 8 mẫu. Tổng hai nhóm là 34 trong 43 dự đoán sai của AST, tương đương khoảng 79,07%. Vì vậy, tập trung xem lại hai cặp này có giá trị hơn việc chỉ tăng độ sâu mạng mà chưa phân tích dữ liệu lỗi.

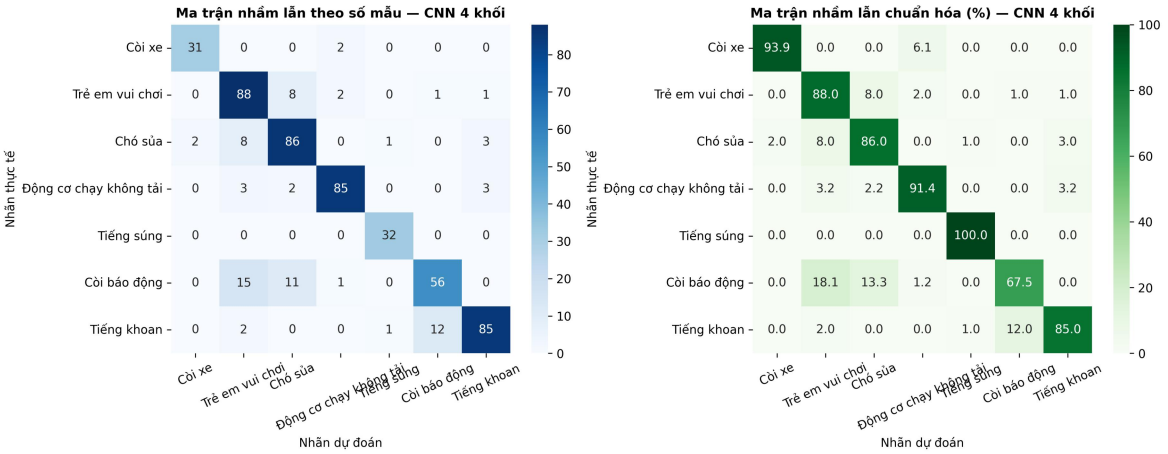


Hình 5.8 Các cặp nhãn nhầm lẫn xuất hiện nhiều nhất

Nguồn: kết quả thực nghiệm của nhóm.

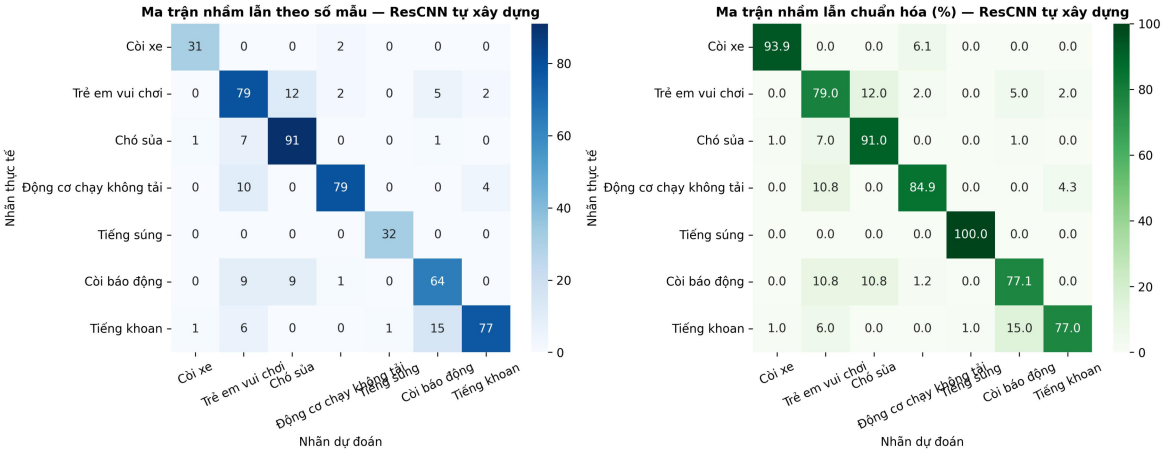
Cấu trúc phổ có thể là một yếu tố liên quan đến nhầm lẫn, nhưng chưa đủ để xác định nguyên nhân của từng mẫu. Cần nghe lại tệp, kiểm tra mức nổi bật của nguồn âm, độ dài sự kiện và môi trường thu. Khi chưa có bảng chú giải thủ công cho từng

lỗi, báo cáo chỉ nêu giả thuyết về sự giống nhau của tín hiệu, không khẳng định mô hình đã "nghe" một đặc trưng cụ thể.



Hình 5.9 Ma trận nhầm lẫn của CNN4

Nguồn: kết quả thực nghiệm của nhóm.

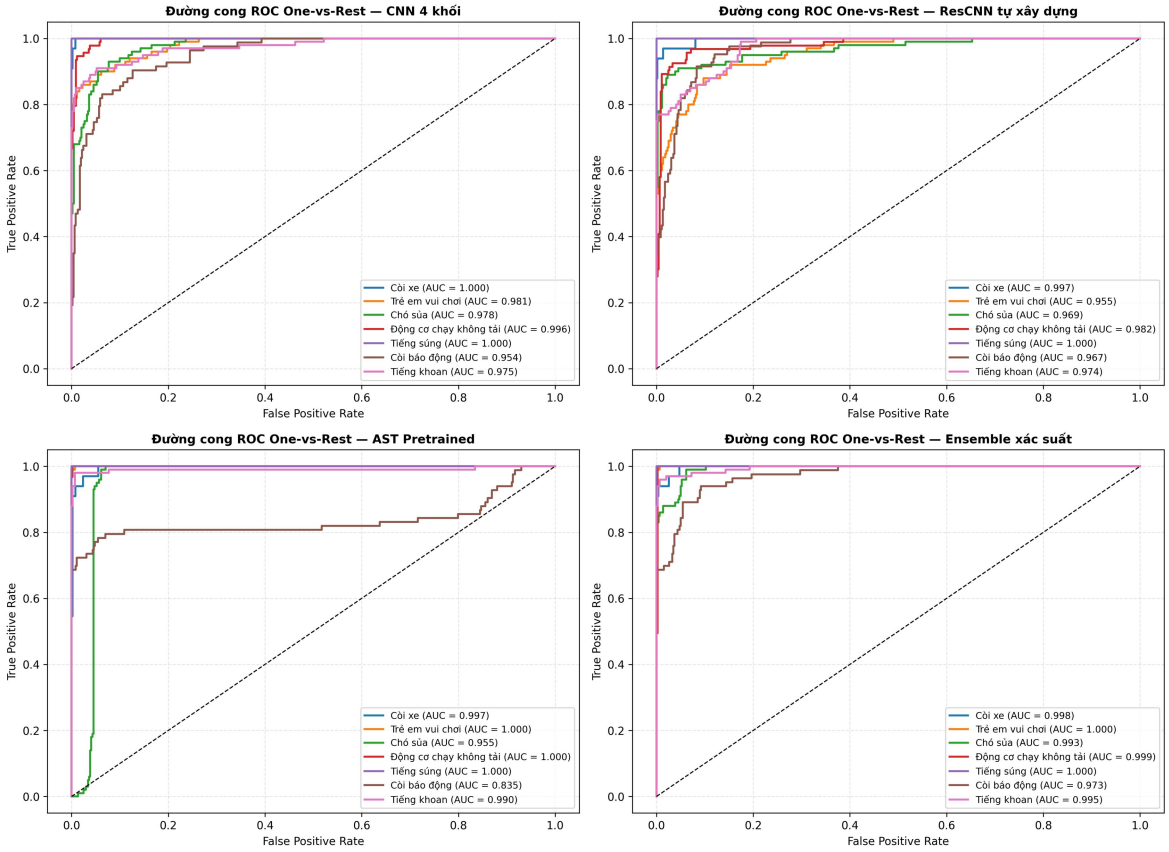


Hình 5.10 Ma trận nhầm lẫn của ResCNN

Nguồn: kết quả thực nghiệm của nhóm.

Các ma trận riêng giúp xem liệu cùng một cặp lớp có khó với nhiều kiến trúc hay không. Nếu nhiều mô hình cùng sai trên một nguồn, cần ưu tiên kiểm tra dữ liệu và bối cảnh nguồn đó. Nếu chỉ một mạng sai, có thể xem tiếp đặc trưng, tăng cường hoặc độ tin cậy đầu ra. Ensemble chỉ hữu ích khi những lỗi của các mạng đủ bổ sung cho nhau; cùng chia sẻ một lỗi lớn sẽ hạn chế hiệu quả kết hợp.

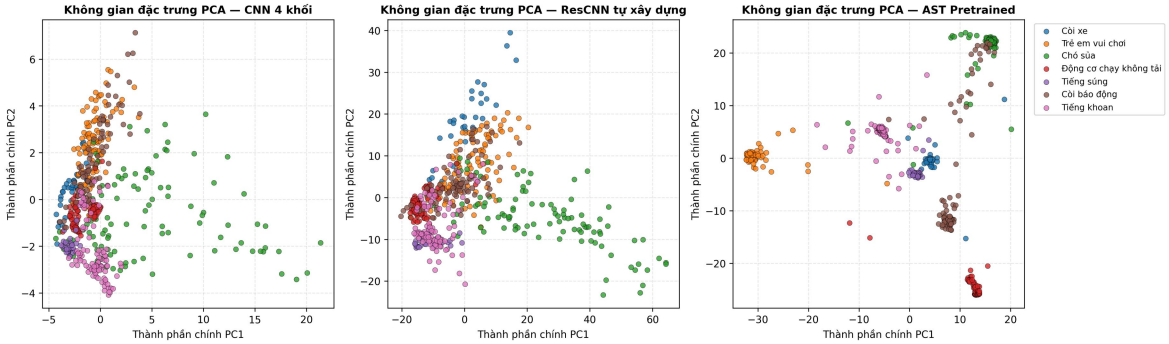
5.6 ROC và biểu diễn đặc trưng



Hình 5.11 Đường ROC theo cách one-vs-rest của các mô hình

Nguồn: kết quả thực nghiệm của nhóm.

Đường ROC cho biết sự thay đổi giữa tỉ lệ dương tính thật và dương tính giả khi thay ngưỡng điểm một lớp. Đây là phân tích bổ sung cho bài toán nhiều lớp. Trong ứng dụng, quyết định dựa trên argmax cùng ngưỡng tham khảo cho xác suất cực đại, nên AUC cao không bảo đảm mọi nhãn argmax đều đúng. Các đường cần được đọc cùng confusion matrix và F1 tại quy tắc quyết định thực tế.



Hình 5.12 Chiếu PCA hai chiều của đặc trưng các mô hình

Nguồn: kết quả thực nghiệm của nhóm.

PCA giữ những hướng có phương sai lớn nhưng không được tối ưu để bảo toàn ranh giới nhãn trong hai chiều. Những cụm nhìn tách biệt có thể bị ảnh hưởng bởi cách lấy mẫu, chuẩn hóa hoặc nguồn ghi âm. Hình 5.12 giúp khảo sát biểu diễn, không thay thế số liệu kiểm tra và không chứng minh AST hiểu được bản chất vật lý của từng âm thanh.

5.7 Chi phí tính toán và lựa chọn triển khai

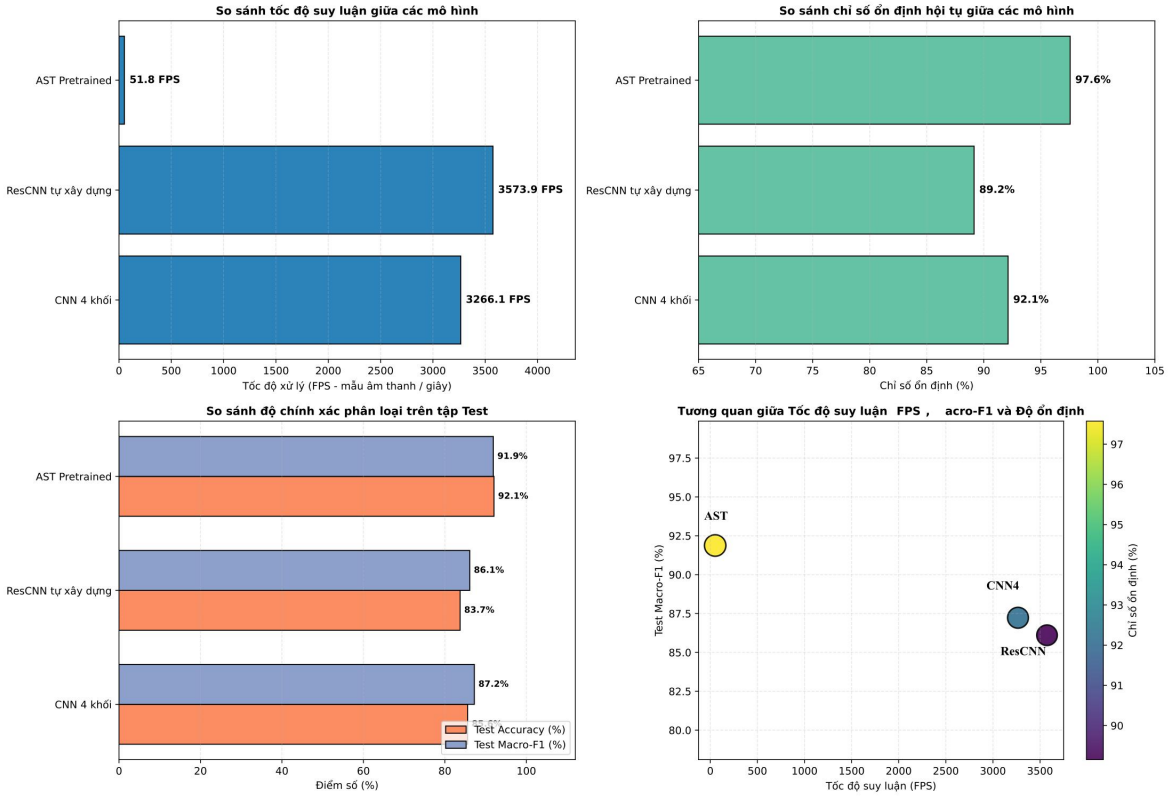
Bảng 5.3 Quy mô mô hình và thời gian huấn luyện đã ghi nhận

Mô hình	Tham số (triệu)	Checkpoint (MiB)	Train (s)	Clip/giây
CNN 4 khối	1,206	4,627	250,75	3266,05
ResCNN tự xây dựng	2,560	9,815	160,90	3573,88
AST Pretrained	86,194	328,887	5414,73	51,76

CNN4 có checkpoint khoảng 4,627 MB và ResCNN khoảng 9,815 MB; AST khoảng 328,887 MB. Thời gian huấn luyện ghi nhận lần lượt khoảng 250,75 giây, 160,90 giây và 5.414,73 giây. Các tổng thời gian này chịu ảnh hưởng của số epoch thực chạy, dừng sớm, đọc dữ liệu và quá trình tiền xử lý. Không nên chỉ từ tổng thời gian kết luận một kiến trúc luôn nhanh hơn trong mọi cấu hình.

Tệp benchmark ghi tốc độ khoảng 3.266 clip/giây cho CNN4, 3.574 clip/giây cho ResCNN và 51,76 clip/giây cho AST. Đây là tốc độ theo thủ tục benchmark của notebook, không phải số khung hình video. Các phép đo sử dụng đầu vào đã chuẩn

bị và đồng bộ thiết bị quanh vùng đo; không bao gồm đầy đủ đọc tệp, giải mã, resample, hiển thị giao diện và xử lý tệp dài. Vì vậy, không dùng nghịch đảo tốc độ này làm cam kết độ trễ đầu cuối.



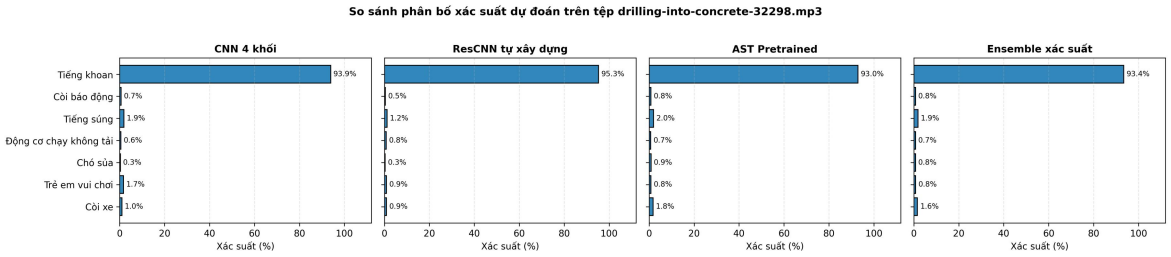
Hình 5.13 Tổng hợp quy mô tốc độ và chất lượng của các mô hình

Nguồn: kết quả thực nghiệm của nhóm.

Chỉ số "ổn định" trong hình là thước đo tổng hợp do notebook xây dựng từ dao động validation và khoảng cách train–validation, không phải một chỉ số chuẩn của UrbanSound8K. Báo cáo chỉ xem đây là mô tả phụ của lần chạy. Nó không đo độ ổn định giữa nhiều seed, nhiều địa điểm thu hoặc nhiều thiết bị. Các quyết định triển khai nên ưu tiên chỉ số phân loại, giới hạn bộ nhớ và phép đo ứng dụng thực tế.

Nếu mục tiêu là bản demo có chất lượng cao trên tập nhãn hiện tại, AST là lựa chọn phù hợp theo số liệu test đã có. Nếu cần dung lượng nhỏ và tốc độ cao trên phần cứng hạn chế, CNN4 đáng xem xét với mức giảm chất lượng đã định lượng. Chưa đủ dữ liệu để kết luận phương án nào tốt nhất trên điện thoại hoặc thiết bị nhúng vì đề tài chưa benchmark các nền tảng đó.

5.8 Minh họa suy luận và kiểm tra ứng dụng



Hình 5.14 So sánh dự đoán trên mẫu âm thanh minh họa của notebook

Nguồn: kết quả thực nghiệm của nhóm.

Mẫu minh họa trong notebook được lấy từ đường dẫn tiếng khoan trên Kaggle. Kết quả giúp kiểm tra luồng xử lý từ tệp đến xác suất của các mô hình. Một mẫu này không đại diện cho khả năng tổng quát ngoài dữ liệu huấn luyện, cũng không thay thế tập test. Tệp âm thanh gốc của ví dụ không có trong gói đầu ra cục bộ nên cần giữ lại khi chuẩn bị trình diễn có thể tái lập.

Ứng dụng có các kiểm tra cho tệp âm thanh hợp lệ, im lặng, tệp rỗng và xác suất đầu ra. Đối với thử nghiệm demo, cần xác nhận bộ kiểm thử của đúng phiên bản đóng gói và đo lại thời gian xử lý trên máy trình bày. Báo cáo không gán trạng thái kiểm thử đạt cho những lần chạy không có nhật ký xác nhận đi kèm.

Khi thử tệp ngoài tập dữ liệu, cần nghe lại nội dung và xem phân bố xác suất của cả bảy lớp. Một nhãn có điểm cao không đủ chứng minh dự đoán đúng, nhất là khi tệp có nhiều nguồn âm hoặc nằm ngoài tập nhãn. Với tệp dài, kết quả tổng hợp còn phụ thuộc cách chia cửa sổ. Do đó, demo phù hợp để quan sát hành vi của mô hình và phát hiện tình huống cần kiểm tra thêm, chưa phải công cụ đánh giá thay cho một tập dữ liệu có nhãn.

5.9 Giới hạn và nguy cơ sai lệch

Giới hạn lớn nhất là đánh giá trên một fold và một seed. Mức chênh lệch giữa validation và test cho thấy các fold không có độ khó đồng nhất. Cần chạy đủ mười fold với cùng quy tắc kiểm soát nguồn, sau đó báo cáo trung bình và độ phân tán. Nếu tiếp tục tinh chỉnh dựa trên lỗi test hiện tại, tập này sẽ trở thành một phần của quá trình phát triển và cần một tập kiểm tra độc lập mới.

Giới hạn thứ hai là phạm vi bảy lớp và nhãn đơn. Âm thanh thực tế có thể chứa nhiều sự kiện, ngoài lớp hoặc chất lượng thu khác dữ liệu công khai. Softmax luôn phân phối điểm trên các nhãn đã biết; ngưỡng 0,60 chưa làm hệ thống thành bộ nhận diện ngoài lớp. Cần dữ liệu unknown, hiệu chuẩn và cách đánh giá mở nếu muốn đưa ra kết luận rộng hơn.

Giới hạn thứ ba là sự khác nhau giữa mô hình pretrained và mạng huấn luyện từ đầu. AST đã hưởng lợi từ dữ liệu pretraining lớn, trong khi CNN chỉ học trên train của đề tài. Kết quả phản ánh hiệu quả của toàn bộ phương án, không chứng minh riêng Transformer vượt CNN khi được cung cấp cùng dữ liệu và ngân sách tính toán.

Cuối cùng, các tệp cấu hình chưa thống nhất hoàn toàn làm giảm mức độ tái lập khi chuyển môi trường. Thông số trong chương 4 và phụ lục được gắn với notebook đã chạy; phiên bản triển khai cần được khóa lại trước khi bàn giao. Đây là giới hạn kỹ thuật có thể khắc phục bằng quản lý phiên bản và manifest, không nên che đi bằng cách gộp thông số từ nhiều lần chạy.

CHƯƠNG 6
KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1 Những nội dung đã thực hiện

Khóa luận đã xây dựng và phân tích một quy trình phân loại bảy nhóm âm thanh đô thị từ UrbanSound8K. Quy trình bao gồm kiểm tra tệp, kiểm soát giao nhau theo nguồn, trích xuất đặc trưng, chuẩn hóa trên train, huấn luyện ba mô hình và đánh giá ensemble. Kết quả được lưu thành CSV, checkpoint và hình vẽ để có thể truy ngược từ nhận xét về dữ liệu.

Trong lần đánh giá test fold 10, AST đạt accuracy 92,05% và macro-F1 91,88%, tốt hơn hai CNN huấn luyện từ đầu. CNN4 cho kết quả cao hơn ResCNN dù có ít tham số hơn. Ensemble chưa cải thiện test macro-F1 so với AST. Những kết quả này trả lời các câu hỏi của đề tài trong phạm vi phép chia đã dùng, chưa phải kết luận chung cho mọi tập âm thanh đô thị.

Phân tích lỗi chỉ ra còi báo động thành chó sủa và tiếng khoan thành còi xe là hai nhóm cần ưu tiên xem lại. Kết quả theo lớp giúp nhận ra khác biệt giữa bỏ sót và dự đoán nhầm mà accuracy tổng không thể hiện rõ. Việc đối chiếu notebook với các tệp mã rời cũng làm rõ yêu cầu giữ nhất quán kiến trúc và tiền xử lý khi triển khai.

Ứng dụng cục bộ đã có các thành phần phục vụ tải tệp, ghi âm, lựa chọn mô hình và xem xác suất. Tuy nhiên, chức năng ngưỡng từ chối chỉ có ý nghĩa tham khảo; phép đo tốc độ trong notebook chưa đại diện độ trễ của toàn bộ ứng dụng. Đây là hai điểm cần phân biệt khi trình bày kết quả nghiên cứu và khả năng sử dụng thực tế.

6.2 Hướng phát triển

Hướng ưu tiên là hoàn thiện giao thức đánh giá. Nhóm cần chạy đủ mười fold, lặp nhiều seed và lưu dự đoán từng mẫu để so sánh cặp mô hình trên cùng dữ liệu. Đồng thời, kiểm tra nguồn giao nhau cần được mở rộng sang các bản ghi gần trùng và nguồn pretraining nếu có thông tin phù hợp. Kết quả khi đó sẽ có cơ sở hơn để so sánh với nghiên cứu khác.

Hướng tiếp theo là phân tích dữ liệu lỗi có chú giải. Với hai cặp nhãn khó, cần nghe lại mẫu, ghi nhận nguồn âm nền, độ nổi bật và thời lượng sự kiện. Sau đó mới thiết kế tăng cường hoặc cân bằng mẫu có mục tiêu. Cách làm này giúp tránh thử nhiều kiến trúc nhưng không giải quyết đúng nguyên nhân của sai số.

Đối với mô hình, có thể thực hiện ablation cho SE, pooling kép, label smoothing và tăng cường dữ liệu. Mỗi thí nghiệm chỉ thay đổi một nhóm yếu tố và giữ nguyên danh sách mẫu. Học chuyển giao từ AST cũng có thể được so sánh với backbone pretrained khác hoặc một CNN pretrained trên âm thanh để giảm sự chênh lệch về lịch sử dữ liệu giữa hai hướng.

Về triển khai, cần khóa bộ cấu hình đi cùng checkpoint, xuất chính xác trọng số ensemble và đo thời gian đầu cuối trên máy đích. Những phương án giảm kích thước như lượng tử hóa hoặc chưng cất chỉ nên được lựa chọn sau khi có số liệu về độ giảm chất lượng và mức tiết kiệm tài nguyên. Nếu mở rộng ra môi trường thực, cần dữ liệu nhiều nguồn âm, ngoài lớp và thiết bị thu khác nhau trước khi đưa ra nhận định về độ tin cậy.

TÀI LIỆU THAM KHẢO

Tiếng Anh

[1] Gong, Y., Chung, Y.-A., Glass, J. (2021), "AST: Audio Spectrogram Transformer", Proceedings of Interspeech 2021, tr. 571–575. DOI: 10.21437/Interspeech.2021-698. https://arxiv.org/abs/2104.01778

[2] He, K., Zhang, X., Ren, S., Sun, J. (2015), "Deep Residual Learning for Image Recognition", arXiv:1512.03385. https://arxiv.org/abs/1512.03385

[3] Hu, J., Shen, L., Albanie, S., Sun, G., Wu, E. (2019), "Squeeze-and-Excitation Networks", arXiv:1709.01507v4, bản mở rộng của công trình CVPR 2018. https://arxiv.org/abs/1709.01507

[4] MIT (không ghi năm), "ast-finetuned-audioset-10-10-0.4593", thẻ mô hình và checkpoint trên Hugging Face. https://huggingface.co/MIT/ast-finetuned-audioset-10-10-0.4593 (truy cập 19/10/2026).

[5] Park, D. S., Chan, W., Zhang, Y., Chiu, C.-C., Zoph, B., Cubuk, E. D., Le, Q. V. (2019), "SpecAugment: A Simple Data Augmentation Method for Automatic Speech Recognition", Proceedings of Interspeech 2019, tr. 2613–2617. DOI: 10.21437/Interspeech.2019-2680. https://arxiv.org/abs/1904.08779

[6] Salamon, J., Jacoby, C., Bello, J. P. (2014), "A Dataset and Taxonomy for Urban Sound Research", Proceedings of the 22nd ACM International Conference on Multimedia, tr. 1041–1044. DOI: 10.1145/2647868.2655045. https://www.justinsalamon.com/uploads/4/3/9/4/4394963/salamon_urbansound_acmmm14.pdf

[7] Salamon, J., Bello, J. P. (2016), "Deep Convolutional Neural Networks and Data Augmentation for Environmental Sound Classification", arXiv:1608.04363. https://arxiv.org/abs/1608.04363

[8] Urban Sound Datasets (không ghi năm), “UrbanSound8K”, mô tả dữ liệu, metadata và khuyến nghị đánh giá. https://urbansounddataset.weebly.com/urbansound8k.html (truy cập 19/10/2026).

[9] Walden, F., Dasgupta, S., Rahman, M., Islam, M. (2022), “Improving the Environmental Perception of Autonomous Vehicles using Deep Learning-based Audio Classification”, arXiv:2209.04075. https://arxiv.org/abs/2209.04075

PHỤ LỤC

A DỮ LIỆU VÀ KHẢ NĂNG TÁI LẬP

Các đường dẫn dưới đây tương đối với thư mục dự án urban_sound. Bảng tập hợp tệp cần thiết để kiểm tra thông số và kết quả. Giá trị trong báo cáo được làm tròn khi trình bày; tệp CSV giữ giá trị số gốc.

Bảng A.1 Các tệp dùng để kiểm tra số liệu

Tệp hoặc thư mục	Nội dung đối chiếu
urbansoundclassification.ipynb	Mã đã chạy; môi trường; cấu hình; đầu ra từng cell
outputs/data/audit.json	Số mẫu hợp lệ, tệp lỗi, nguồn giao fold và trùng băm
outputs/data/split_fold10.json	Fold và số mẫu sau loại nguồn trùng
outputs/data/split_class_distribution.csv	Số mẫu từng lớp trên ba tập
outputs/data/cnn_norm_fold10.npz	Thống kê chuẩn hóa theo dải Mel
outputs/logs/*_history.csv	Loss, accuracy, F1 và thời gian qua epoch
outputs/metrics/test_summary_metrics.csv	Chỉ số tổng thể của bốn phương án
outputs/metrics/per_class_detailed_metrics.csv	Precision, recall và F1 từng lớp
outputs/metrics/benchmark_fps_stability_accuracy.csv	Tham số, dung lượng, thời gian và throughput
outputs/checkpoints/*_best.pt	Trọng số đã lưu của từng mô hình
configs/ast_processor/; configs/labels.json	Bộ xử lý AST và thứ tự bảy nhãn

A.1 Quy trình kiểm tra lại kết quả

Đầu tiên, đối chiếu ba tổng số mẫu với split_fold10.json và bảng phân bố lớp. Tiếp theo, kiểm tra thứ tự nhãn trong configs/labels.json trước khi đọc các ma trận. Sau đó, dùng test_summary_metrics.csv để dựng bảng tổng thể và per_class_detailed_metrics.csv để dựng bảng theo lớp. Khi vẽ lại learning curves, lấy trực tiếp history của mô hình tương ứng, không suy ra từ hình PNG đã nén.

Lệnh chạy ứng dụng tại thư mục dự án: .\run_windows.bat. Điểm vào Python là app.py. Các lệnh dự đoán và vẽ biểu đồ được lưu tại scripts/predict.py và scripts/plot_results.py. Cần đối chiếu đường dẫn đầu ra mà script hỗ trợ với cấu trúc checkpoint thực tế trước khi chạy lại. Không dùng việc chương trình mở được giao diện làm bằng chứng rằng số liệu thực nghiệm đã được tái lập.

A.2 Thông số cần giữ nhất quán

Bản notebook được phân tích dùng CustomCNN4 hai tích chập 3 × 3 mỗi khối và CustomResCNN có SE. Các tệp cnn4_architecture.txt và rescnn_architecture.txt trong configs mô tả một biến thể cũ hơn. Tương tự, thống kê toàn cục trong stats_fold10.json không thay thế thống kê theo dải ở cnn_norm_fold10.npz. Khi bàn giao cần đóng gói cấu hình khớp tên và kích thước tensor của checkpoint, kèm checksum để phân biệt phiên bản.

Bộ trọng số ensemble tối ưu và xác suất validation từng mẫu cần được xuất cùng bản notebook để tái lập phép kết hợp. Nếu ứng dụng không tìm thấy ensemble.json và dùng trung bình đều, kết quả được hiểu là ensemble demo. Bảng 5.1 không được gán cho cấu hình trung bình đều nếu chưa kiểm tra chúng trùng nhau.

A.3 Kịch bản kiểm tra trước buổi trình bày

Chuẩn bị ít nhất một tệp WAV rõ nguồn, một tệp im lặng và một tệp không hợp lệ. Với tệp hợp lệ, kiểm tra tổng bảy xác suất gần bằng 1, thứ tự tên lớp, thời lượng hiển thị và mô hình đã chọn. Với tệp im lặng hoặc lỗi, kiểm tra thông báo phù hợp và giao diện còn sử dụng được. Với tệp dài, đo riêng thời gian tiền xử lý, thời gian mô hình và tổng thời gian phía ứng dụng.

Phần trình bày slide nên đi theo mạch: bài toán, phạm vi bảy lớp, dữ liệu và kiểm soát nguồn, ba kiến trúc, cấu hình huấn luyện, kết quả tổng thể, lỗi theo lớp, demo và hạn chế. Các biểu đồ dùng trên slide cần giữ nhãn test fold 10. Không đổi nhãn thành kết quả mười fold khi chưa thực hiện đủ các lượt đánh giá.

NHẬT KÝ LÀM VIỆC

Đề tài: Phân loại âm thanh đô thị sử dụng Deep Learning

Sinh viên: Lương Công Phú Boy - 22002515; Trần Anh Khoa - 22000915.

Giảng viên hướng dẫn: TS. Huỳnh Công Bằng; TS. Nguyễn Minh Hạnh.

Thời gian tổng hợp: 16/6/2026 đến 19/10/2026.

Bảng tiến độ dự thảo để hai sinh viên đối chiếu và xác nhận theo lịch thực hiện. Ngày báo cáo và nhận xét của giảng viên được để trống.

Bảng B.1 Nhật ký công việc theo tuần

Tuần	Từ ngày	Đến ngày	Ngày báo cáo GVHD	Nội dung công việc	Nhận xét GVHD
1	16/06	22/06		Khảo sát bài toán phân loại âm thanh đô thị. Lập đề cương và phạm vi đề tài.	
2	23/06	29/06		Tìm hiểu UrbanSound8K và nguồn dữ liệu. Đọc tài liệu CNN cho âm thanh môi trường.	
3	30/06	06/07		Khảo sát metadata, nhãn và cấu trúc fold. Tổng hợp tài liệu tham khảo ban đầu.	
4	07/07	13/07		Xây dựng mã đọc và kiểm tra tệp âm thanh. Viết phần giới thiệu bài toán.	
5	14/07	20/07		Thực hiện chuyển mono, resample và cửa sổ 4 giây. Khảo sát waveform và Log-Mel.	
6	21/07	27/07		Thiết kế chia train, validation, test theo fold. Kiểm tra fsID và mã băm tệp.	
7	28/07	03/08		Xây dựng CNN4 và pipeline đặc trưng. Soạn phần cơ sở lý thuyết CNN.	
8	04/08	10/08		Xây dựng ResCNN với kết nối phần dư và SE. Bổ sung sơ đồ kiến trúc vào báo cáo.	
9	11/08	17/08		Tích hợp bộ xử lý và checkpoint AST. Tìm hiểu cơ chế fine-tuning và AMP.	
10	18/08	24/08		Hoàn thiện tăng cường dữ liệu và hàm mất mát. Kiểm tra quy trình chọn checkpoint theo validation.	

Phân loại âm thanh đô thị sử dụng Deep Learning

Tuần	Từ ngày	Đến ngày	Ngày báo cáo GVHD	Nội dung công việc	Nhận xét GVHD
11	25/08	31/08		Tổ chức nhật ký loss, accuracy và macro-F1. Hoàn thiện mã lưu kết quả thực nghiệm.	
12	01/09	07/09		Xây dựng ensemble xác suất trên validation. Chuẩn bị mã tính chỉ số theo lớp.	
13	08/09	14/09		Tạo confusion matrix, ROC và biểu diễn PCA. Viết phần phương pháp đánh giá.	
14	15/09	21/09		Hoàn thiện luồng suy luận từ checkpoint. Xây dựng giao diện Gradio cho tệp và ghi âm.	
15	22/09	28/09		Kiểm tra trường hợp tệp lỗi, im lặng và âm thanh dài. Chỉnh cách hiển thị xác suất trong demo.	
16	29/09	05/10		Rà soát số liệu và các cặp nhãn nhầm lẫn. Biên soạn chương thực nghiệm và thảo luận.	
17	06/10	12/10		Soạn nội dung slide và kịch bản demo. Rà soát trích dẫn, bảng và hình trong báo cáo.	
18	13/10	19/10		Tổng hợp lần chạy notebook và đối chiếu cấu hình. Hoàn thiện báo cáo, nội dung slide và nhật ký đến 19/10/2026.	

Xác nhận của sinh viên

Lương Công Phú Boy Trần Anh Khoa